



UNIVERSIDAD DE MÁLAGA



Trabajo fin de grado

Sistema de tracking y reidentificación de jugadores en fútbol amateur

Realizado por
Soriano Muñoz Juan Ignacio

Profesor encargado:
Luque Baena Rafael Marcos
Jerez Aragonés Jose Manuel
Departamento
Lenguajes y Ciencias de la Computación

MÁLAGA, DICIEMBRE de 2024



UNIVERSIDAD
DE MÁLAGA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA
ESTUDIANTES DE INGENIERÍA BIOINFORMÁTICA

Sistema de tracking y reidentificación de jugadores en fútbol amateur

Trabajo fin de grado

Realizado por
Soriano Muñoz Juan Ignacio

Profesor encargado:
Luque Baena Rafael Marcos
Jerez Aragonés Jose Manuel

Departamento
Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA
MÁLAGA, DICIEMBRE DE 2024

Índice

1. Introducción	6
1.1. Contexto del problema	6
1.2. Motivación	6
1.3. Objetivos del TFG	7
1.4. Alcance y limitaciones	8
1.5. Estructura de la memoria	8
2. Estado del arte	9
2.1. Multi-Object Tracking	9
2.2. Re-Identification	9
2.3. Paradigmas de seguimiento: <i>tracking-by-detection</i> frente a métodos <i>end-to-end</i>	10
2.4. Seguimiento de jugadores en deporte y fútbol	11
2.5. Métricas de evaluación	12
3. Planteamiento del problema	14
3.1. Dificultades específicas del dominio amateur	14
3.2. Oclusiones, cruces, paneos y salidas de escena	14
3.3. Coherencia de identidad y coherencia geométrica	15
3.4. Preguntas de investigación	16
3.5. Hipótesis de trabajo	17
4. Datos, materiales y entorno experimental	18
4.1. Datasets utilizados	18
4.2. Secuencias profesionales y amateur	18
4.3. Ground truth y pseudo-ground-truth	18
4.4. Entorno tecnológico	18
4.5. Organización reproducible de experimentos	18

5. Metodología general	19
5.1. Diseño iterativo del trabajo	19
5.2. Flujo general del pipeline	19
5.3. Protocolo de evaluación cuantitativa	21
5.4. Protocolo de evaluación cualitativa	22
5.5. Jerarquía de resultados: definitivos frente a exploratorios	22
6. Comparativa inicial de trackers	24
6.1. Selección de trackers candidatos	25
6.2. ByteTrack	26
6.3. DeepEIoU	27
6.4. MOTIP	27
6.5. Resultados iniciales y selección del tracker base	28
7. Diagnóstico del problema de identidad	30
7.1. Análisis visual de fallos en ByteTrack	31
7.2. Casos críticos: oclusiones, jugador caído y teletransportación	33
7.3. Influencia del <code>track_buffer</code>	34
7.4. Heurísticas tempranas y sus limitaciones	35
7.5. Conclusión del diagnóstico	36
8. Análisis del módulo ReID	38
8.1. Planteamiento del análisis	39
8.2. Fase 0: auditoría y preparación del experimento	39
8.3. Fase 1: validación del embedding puro	41
8.4. Estructura del espacio de embeddings: t-SNE, PCA y similitud	43
8.5. Estabilidad temporal del embedding	45
8.6. Fase 2: ¿qué información visual usa el modelo?	46
8.7. Fase 3: comparación entre embedding puro y tracker	48
8.8. Discusión: qué demuestra realmente este estudio	49

9. Integración online de ReID en ByteTrack	50
9.1. Motivación de la recalibración online	51
9.2. Diseño de las configuraciones v0, v1, v2 y v3	52
9.3. Por qué la guardia IoU de v3 no duplica el IoU nativo de ByteTrack .	53
9.4. Resultados cuantitativos de la recalibración	53
9.5. Lectura funcional del trade-off	54
9.6. Evaluación cualitativa de v1	55
9.7. Errores espaciales representativos	56
9.8. Conclusión del enfoque online y transición al linking	57
10. Postprocesado offline mediante tracklet linking	59
10.1. Motivación del tracklet linking	60
10.2. Construcción y análisis de tracklets	60
10.3. Linking geométrico y criterios de fusión	61
10.4. Experimentos principales sobre v0	62
10.5. Aplicación sobre v1	63
10.6. Generalización a múltiples secuencias	64
10.7. Discusión: online frente a offline	65
11. Adaptación del ReID al dominio	66
11.1. Modelo baseline SportsMOT	67
11.2. Curvas de aprendizaje y selección de checkpoints	67
11.3. Entrenamiento específico en fútbol profesional	69
11.4. Entrenamiento específico en fútbol amateur	70
11.5. Comparación entre modelos genéricos y específicos	71
11.6. Aplicación de tracklet linking sobre los mejores modelos	71
12. Curación manual de resultados y herramienta de apoyo	73
12.1. Necesidad de corrección manual en salidas MOT	73
12.2. Script <code>annotate_review.py</code>	73
12.3. Script <code>annotate_review_precise.py</code>	73

12.4. Aplicación web Gradio del pipeline completo	73
12.5. Utilidad práctica dentro del flujo experimental	73
12.6. Limitaciones actuales de la herramienta	73
13.Resultados globales y selección del sistema final	74
13.1. Megatabla de configuraciones	74
13.2. Comparación global de enfoques	74
13.3. Criterios de selección del sistema final	74
13.4. Pipeline final elegido y justificación	74
13.5. Discusión sobre trade-offs	74
14.Conclusiones	75
14.1. Respuesta a los objetivos del anteproyecto	75
14.2. Principales hallazgos	75
14.3. Aportaciones del trabajo	75
14.4. Limitaciones	75
14.5. Trabajo futuro	75

1. Introducción

1.1. Contexto del problema

El seguimiento multiobjeto (*Multi-Object Tracking*, MOT) es una tarea central de la visión por computador que persigue estimar la trayectoria y mantener la identidad de múltiples objetos a lo largo del tiempo en una secuencia de vídeo. En los sistemas modernos, el paradigma dominante es *tracking-by-detection*, en el que primero se detectan los objetos en cada fotograma y, posteriormente, se resuelve su asociación temporal mediante pistas geométricas, dinámicas y de apariencia [1, 6, 7].

En el ámbito deportivo, y particularmente en fútbol, este problema adquiere una relevancia práctica inmediata. Un sistema de tracking robusto permite estimar posiciones, trayectorias, ocupación espacial, distancias recorridas y patrones colectivos, información que resulta útil tanto para analítica táctica como para generación automática de estadísticas. Sin embargo, los vídeos de retransmisión plantean dificultades específicas: fuertes cambios de cámara, oclusiones frecuentes, cruces entre jugadores, escalas variables, similitud visual entre futbolistas del mismo equipo y desapariciones temporales al salir del campo visual [2, 3].

La disponibilidad de benchmarks específicos ha permitido estudiar este problema de forma más sistemática. SoccerNet-Tracking formaliza el seguimiento de jugadores, árbitros y balón en vídeo de fútbol, y muestra que el problema está lejos de resolverse en escenarios con movimiento rápido y oclusión severa [2]. Por su parte, SportsMOT amplía el análisis a varios deportes y concluye que, en escenas deportivas, una parte sustancial de la dificultad reside en la asociación de identidades, no solo en la detección [3].

1.2. Motivación

Este trabajo nace de una necesidad doble. Por un lado, existe interés en disponer de un pipeline de seguimiento aplicable a fútbol amateur, donde habitualmente no se cuenta con sistemas comerciales de captura, sensores invasivos ni recursos de anotación abundantes. Por otro, aunque trackers generales como ByteTrack ofrecen muy buen rendimiento en benchmarks estándar, su comportamiento en fútbol no es directamente óptimo, especialmente cuando la calidad de la señal visual, las oclusiones y la reentrada de jugadores en escena degradan la consistencia de identidad [7, 2].

A ello se suma el hecho de que los métodos basados en apariencia, normalmente implementados mediante módulos de *person re-identification* (ReID), pueden ayu-

dar a reducir cambios de identidad al complementar la asociación geométrica. Deep SORT mostró tempranamente que incorporar una métrica profunda de apariencia podía reducir los *identity switches* al atravesar oclusiones más largas [6]. Sin embargo, en entornos deportivos la apariencia también resulta ambigua: jugadores del mismo equipo comparten colores, la resolución de los dorsales no siempre es suficiente y los cambios de pose o escala pueden deteriorar la utilidad del embedding visual [3, 2].

La motivación concreta del TFG consiste, por tanto, en estudiar de forma experimental hasta qué punto un pipeline basado en ByteTrack puede adaptarse al dominio del fútbol mediante tres vías complementarias: la integración online de ReID, el postprocesado offline mediante *tracklet linking* y el ajuste de modelos de ReID al dominio específico. Además, se persigue que el resultado no sea solo un análisis teórico, sino también una herramienta utilizable para ejecutar experimentos, visualizar resultados y evaluar secuencias con y sin *ground truth*.

1.3. Objetivos del TFG

El objetivo general de este trabajo es diseñar, analizar y evaluar un pipeline de seguimiento multiobjeto aplicado a fútbol, con especial atención a la continuidad de identidad en escenarios profesionales y amateur.

De este objetivo general se derivan los siguientes objetivos específicos:

- Comparar distintos enfoques de tracking multiobjeto y seleccionar una base de trabajo adecuada para el dominio del fútbol.
- Analizar el comportamiento del módulo de re-identificación, tanto de forma aislada como integrado en el tracker, para entender qué información codifica y cuáles son sus limitaciones.
- Estudiar distintas estrategias de integración online de ReID dentro de ByteTrack, evaluando sus ventajas y sus posibles degradaciones.
- Diseñar y validar un postprocesado offline basado en *tracklet linking* para reducir fragmentación e incoherencias geométricas.
- Investigar el impacto del dominio mediante el uso de un modelo genérico de ReID y modelos específicos entrenados para fútbol profesional y amateur.
- Construir una herramienta de apoyo que permita ejecutar el pipeline completo, visualizar resultados y facilitar la evaluación experimental.

1.4. Alcance y limitaciones

El trabajo se centra en seguimiento multiobjeto con una única cámara de vídeo, utilizando secuencias de fútbol profesional y amateur. El núcleo experimental se apoya en ByteTrack como tracker base, modelos OSNet para ReID y un módulo de *tracklet linking* como postprocesado offline. La evaluación se realiza principalmente mediante métricas estándar de MOT, como MOTA, IDF1, HOTA, *ID switches*, fragmentación y número total de identidades, complementadas con análisis cualitativo cuando las métricas por sí solas no capturan errores geoméricamente incoherentes [2, 7, 3].

No obstante, el trabajo presenta también varias limitaciones. En primer lugar, no se aborda un sistema end-to-end de reconstrucción global del estado del partido, sino un pipeline modular centrado en detección, asociación e identidad. En segundo lugar, la parte amateur exige una fase adicional de curación manual para construir un *pseudo-ground truth*, lo que limita la escalabilidad del proceso. Finalmente, aunque se estudian modelos específicos de dominio, el alcance del TFG no incluye un rediseño completo del tracker ni un entrenamiento conjunto detector-ReID-tracker.

1.5. Estructura de la memoria

La memoria se organiza del siguiente modo. En primer lugar, se presenta el estado del arte y el planteamiento del problema. A continuación, se describen los datos, materiales y la metodología general empleada. Después, se desarrolla la comparación inicial de trackers, el diagnóstico del problema de identidad y el análisis del módulo ReID. Sobre esa base, se estudian dos líneas principales de mejora: la integración online de ReID en ByteTrack y el postprocesado offline mediante *tracklet linking*. Posteriormente, se analiza la adaptación del ReID al dominio mediante modelos específicos y se describe la herramienta de apoyo desarrollada para la ejecución del pipeline y la curación manual de resultados. Finalmente, se integran los resultados globales, se justifica la selección del sistema final y se exponen las conclusiones y líneas de trabajo futuro.

2. Estado del arte

2.1. Multi-Object Tracking

El problema de *Multi-Object Tracking* (MOT) consiste en estimar la trayectoria de múltiples objetos a lo largo del tiempo manteniendo una identidad consistente para cada uno de ellos. En visión por computador, esta tarea suele abordarse sobre secuencias de vídeo monocámara y combina dos subproblemas fundamentales: la localización de los objetos en cada fotograma y su asociación temporal entre fotogramas consecutivos o distantes [1, 7].

Aunque buena parte de la literatura se ha desarrollado sobre escenarios peatonales y urbanos, el MOT sigue siendo un problema abierto cuando aparecen oclusiones prolongadas, interacciones densas, cambios bruscos de movimiento o degradación de la apariencia. En estos casos, el rendimiento del tracker depende no solo de la calidad del detector, sino también de la forma en que combina información geométrica, temporal y visual para preservar identidades consistentes [1, 5].

Desde un punto de vista metodológico, la evolución reciente del MOT puede entenderse a partir de dos grandes familias de enfoques: por un lado, los métodos modulares basados en detección, conocidos como *tracking-by-detection*; por otro, los métodos más integrados o *end-to-end*, entre los que destacan varias propuestas basadas en transformers y en predicción directa de identidad. Esta distinción es especialmente relevante para el presente TFG, ya que parte del trabajo consistió precisamente en comparar ambos paradigmas antes de centrar el desarrollo en un pipeline modular.

2.2. Re-Identification

La *Re-Identification* (ReID) es una técnica orientada a representar una identidad mediante un embedding de apariencia que permita comparar recortes de una misma persona u objeto a lo largo del tiempo. En un pipeline de tracking, su función es complementar la asociación geométrica con una señal visual capaz de sostener identidades incluso cuando la predicción dinámica resulta ambigua. En la práctica, un modelo ReID transforma cada recorte en un vector de características y la similitud entre esos vectores se utiliza como criterio adicional de asociación [6, 1].

La incorporación de embeddings profundos a la asociación temporal se popularizó con Deep SORT, que mostró que una métrica de apariencia aprendida podía reducir los cambios de identidad frente a métodos puramente geométricos [6]. Desde enton-

ces, muchos trackers han incorporado módulos ReID como parte central o auxiliar de su estrategia de asociación, especialmente en escenarios donde las oclusiones, los cruces y las desapariciones temporales son frecuentes.

Sin embargo, la utilidad de la ReID depende fuertemente del dominio. En escenas deportivas, y en particular en deportes de equipo, la apariencia entre instancias es simultáneamente parecida y potencialmente discriminativa: varios jugadores comparten colores y estructura visual global, pero pueden diferenciarse por dorsal, textura, pose o detalles locales. SportsMOT subraya que precisamente esta mezcla de movimiento rápido y apariencia redundante convierte la asociación de identidades en el reto dominante del tracking deportivo [3]. Por ello, la efectividad del ReID no depende únicamente de su arquitectura, sino también del dominio en que se entrena y de cómo se integra dentro del tracker.

2.3. Paradigmas de seguimiento: *tracking-by-detection* frente a métodos *end-to-end*

El paradigma más extendido en MOT durante los últimos años ha sido el *tracking-by-detection*. En este esquema, la detección y la asociación se resuelven en etapas separadas: primero se detectan los objetos en cada fotograma y después se enlazan temporalmente mediante información de movimiento, solapamiento espacial, heurísticas de asignación y, en muchos casos, embeddings de apariencia [1, 6, 7]. Este enfoque tiene como principal ventaja su modularidad: cada componente puede mejorarse o sustituirse sin necesidad de rediseñar por completo el sistema.

Deep SORT constituye un ejemplo representativo de esta familia. El método combina un filtro de Kalman para modelar el movimiento, una estrategia clásica de asignación y una métrica profunda de apariencia para reforzar la asociación [6]. Posteriormente, otros métodos mantuvieron esta filosofía modular, aunque introduciendo mejoras específicas en la política de asociación. ByteTrack, por ejemplo, demostró que una parte importante de la fragmentación proviene de descartar demasiado pronto detecciones de baja confianza. Su propuesta consiste en asociar prácticamente todas las cajas de detección, incluidas aquellas con score menor, recuperando así instancias verdaderas que otros trackers perderían [7]. Esta idea resulta especialmente interesante en escenas con oclusión, donde las detecciones válidas tienden a degradarse temporalmente.

Frente a este paradigma modular, en los últimos años han aparecido métodos más integrados o *end-to-end*, en los que la identidad deja de resolverse únicamente como una asignación posterior basada en heurísticas y se incorpora de forma más directa

al propio proceso de predicción. Dentro de esta familia se encuentran varias propuestas basadas en transformers, que aprovechan su capacidad para modelar relaciones globales y dependencias temporales entre múltiples objetos. Estos enfoques aspiran a aprender de forma conjunta qué trayectorias deben mantenerse y cómo propagar la identidad a lo largo del tiempo, reduciendo la dependencia de reglas diseñadas manualmente.

MOTIP ejemplifica bien esta línea de trabajo. En lugar de formular el problema exclusivamente como una asociación entre detecciones frame a frame, plantea el tracking como un problema de predicción de identidad a partir del contexto histórico de las trayectorias [4]. Conceptualmente, esto desplaza parte de la carga del sistema desde el diseño explícito de funciones de coste y reglas de matching hacia un mecanismo aprendido que intenta decidir directamente qué identidad corresponde a cada observación.

Ambos paradigmas presentan fortalezas y debilidades. Los métodos *tracking-by-detection* suelen ser más interpretables, modulares y fáciles de adaptar cuando se desea reemplazar detector, módulo ReID o postprocesado de manera independiente. Los métodos *end-to-end*, por el contrario, pueden capturar dependencias más complejas y reducir la necesidad de heurísticas manuales, pero a cambio suelen ser menos transparentes y más dependientes del dominio de entrenamiento y de la calidad del protocolo experimental [7, 4]. En el contexto del presente trabajo, esta diferencia resultó especialmente relevante: mientras los métodos modulares ofrecían una base clara sobre la que analizar y modificar componentes, los métodos más integrados servían como referencia valiosa de un paradigma alternativo, aunque menos sencillo de intervenir.

2.4. Seguimiento de jugadores en deporte y fútbol

El tracking en deporte comparte la estructura general del MOT, pero introduce dificultades específicas que lo convierten en un dominio especialmente exigente. SportsMOT muestra que los deportes combinan dos propiedades difíciles de resolver simultáneamente: movimiento rápido y variable, y apariencias muy parecidas entre instancias que, aun así, deben distinguirse correctamente [3]. En consecuencia, la asociación es particularmente frágil cuando depende solo de proximidad geométrica o de una apariencia poco discriminativa.

En fútbol, además, el problema tiene una dimensión contextual muy marcada. SoccerNet-Tracking fue propuesto para cubrir la falta de benchmarks específicos de tracking en vídeo futbolístico y puso de manifiesto que el seguimiento conjunto de jugadores, árbitros y balón está lejos de estar resuelto [2]. El benchmark des-

taca fenómenos como oclusión severa, movimiento rápido, densidad de jugadores y dificultad para mantener identidades en secuencias largas de retransmisión.

La importancia de este problema no es únicamente académica. El tracking robusto en fútbol permite automatizar la extracción de trayectorias, estimar carga física, reconstruir ocupación espacial y facilitar análisis táctico sin necesidad de sensores invasivos, algo especialmente valioso en contextos amateur o semiprofesionales [2, 3]. Sin embargo, precisamente en esos contextos la calidad del vídeo suele ser menor y la disponibilidad de anotaciones es más limitada, lo que amplía la distancia entre los resultados de benchmark y la aplicabilidad práctica de los sistemas.

Por ello, una parte relevante del estado del arte reciente en deporte no se limita a proponer trackers más precisos, sino que insiste en la necesidad de datasets y protocolos de evaluación ajustados al dominio. Tanto SoccerNet-Tracking como SportsMOT desempeñan en este TFG un papel central como referencias para contextualizar el problema y justificar las decisiones experimentales adoptadas.

2.5. Métricas de evaluación

La evaluación en MOT requiere medir simultáneamente calidad de detección y calidad de asociación. Tradicionalmente, una de las métricas más utilizadas ha sido MOTA, que resume errores de falsas detecciones, pérdidas y cambios de identidad en una sola magnitud agregada. Junto a ella, métricas como IDF1 ponen el foco en la consistencia de identidad, valorando hasta qué punto las trayectorias predichas corresponden correctamente con las trayectorias reales [5].

No obstante, la literatura reciente ha señalado que estas métricas clásicas no siempre reflejan de forma equilibrada todos los tipos de error relevantes en tracking. HOTA fue propuesta precisamente para afrontar esta limitación, buscando un balance explícito entre detección y asociación y ofreciendo además descomposiciones que permiten interpretar con mayor claridad si una mejora procede de mejores detecciones o de una asociación más consistente [5]. En la práctica, HOTA se ha consolidado como una métrica especialmente útil cuando interesa valorar el comportamiento global de un tracker más allá de una única magnitud agregada.

Junto a estas métricas generales, en aplicaciones concretas resulta habitual analizar también medidas más directamente interpretables, como el número de *ID switches*, las fragmentaciones o el número total de identidades generadas por el sistema. En escenarios deportivos, donde la continuidad por jugador resulta esencial para reconstruir trayectorias largas y extraer estadísticas fiables, estas cantidades pueden llegar a ser tan importantes como las métricas agregadas [2, 5].

En consecuencia, un protocolo de evaluación sólido en MOT no debería descansar sobre una única métrica. La práctica más razonable consiste en combinar métricas globales, métricas centradas en identidad y análisis cualitativo cuando el dominio lo exige. Esta idea será central en el presente trabajo, donde la comparación entre configuraciones no se decide únicamente por la mejora de una métrica aislada, sino por el equilibrio entre continuidad de identidad, reducción de fragmentación y plausibilidad geométrica.

3. Planteamiento del problema

3.1. Dificultades específicas del dominio amateur

El seguimiento multiobjeto en fútbol presenta una dificultad estructural superior a la de otros escenarios de MOT más controlados. A diferencia de entornos urbanos o secuencias peatonales convencionales, en fútbol se combinan movimientos rápidos, aceleraciones bruscas, cambios de dirección frecuentes, agrupamientos densos y una apariencia altamente redundante entre jugadores del mismo equipo. Tanto SoccerNet-Tracking como SportsMOT señalan precisamente que una parte sustancial de la complejidad en escenas deportivas no reside únicamente en detectar correctamente a los jugadores, sino en mantener su identidad de forma consistente a lo largo del tiempo [2, 3].

En el caso concreto del fútbol amateur, estas dificultades se agravan por factores adicionales relacionados con la adquisición del vídeo. Es habitual trabajar con una única cámara, encuadres menos estables, menor resolución efectiva sobre los jugadores, iluminación menos homogénea y ausencia de sistemas auxiliares de sensorización. Como consecuencia, las pistas visuales finas, como el dorsal o detalles locales de textura, tienden a degradarse con facilidad, y la señal disponible para re-identificación se vuelve menos fiable que en secuencias profesionales de mayor calidad. Este problema es especialmente relevante cuando el sistema debe distinguir entre jugadores del mismo equipo cuya apariencia global es muy similar [3, 6].

Desde el punto de vista experimental, el dominio amateur introduce además una limitación metodológica importante: la escasez de anotaciones listas para evaluación y entrenamiento. Mientras que benchmarks como SoccerNet-Tracking proporcionan secuencias anotadas y un protocolo de evaluación bien definido [2], en el contexto amateur es frecuente que el investigador tenga que construir o depurar manualmente un *pseudo-ground truth* para poder calcular métricas consistentes y preparar conjuntos *gallery/query* destinados al entrenamiento de modelos ReID. Esto convierte la curación manual del dato en una parte funcional del pipeline, no solo en una tarea auxiliar.

3.2. Oclusiones, cruces, paneos y salidas de escena

El comportamiento de un tracker en fútbol se ve fuertemente condicionado por varios fenómenos visuales recurrentes. El primero de ellos es la oclusión, tanto parcial como total. Cuando varios jugadores convergen sobre una misma zona del campo, el detector puede producir cajas degradadas, perder temporalmente alguna instancia o

generar asociaciones ambiguas. ByteTrack mostró que recuperar detecciones de baja confianza ayuda a reducir fragmentación causada por oclusiones y bajas puntuaciones del detector [7]; sin embargo, en escenas deportivas con interacción intensa la mera recuperación de detecciones no garantiza por sí sola la coherencia de identidad.

Un segundo fenómeno crítico son los cruces entre trayectorias. Cuando dos o más jugadores intercambian posiciones relativas en pocos fotogramas, la asociación basada exclusivamente en proximidad geométrica puede inducir cambios de identidad si no existe una señal de apariencia suficientemente discriminativa. Deep SORT ya argumentaba que la incorporación de una métrica profunda de apariencia resulta especialmente útil para sostener identidades a través de oclusiones y cruces prolongados [6]. No obstante, en fútbol esa señal de apariencia puede ser ambigua debido a la similitud entre compañeros, de modo que ni la geometría ni la apariencia son completamente fiables por separado.

El tercer factor es el movimiento de cámara. En vídeo de retransmisión, los paneos y cambios de zoom alteran continuamente la localización aparente y la escala de los jugadores. Esto introduce errores tanto en la predicción dinámica del tracker como en la comparación visual entre recortes de una misma identidad tomados bajo perspectivas distintas. SoccerNet-Tracking destaca precisamente que las secuencias de fútbol contienen escenarios especialmente complejos en presencia de movimiento rápido y oclusión severa [2]. En un contexto amateur, donde la estabilización y la calidad óptica suelen ser peores, este efecto puede resultar todavía más acusado.

Finalmente, las salidas y reentradas de escena generan un problema de largo alcance. Un jugador puede abandonar el campo visual por un lateral y reaparecer decenas de fotogramas después en una posición muy distinta debido al paneo de cámara. Si la memoria temporal del tracker es demasiado corta, se fragmenta la trayectoria; si es demasiado larga, aumenta el riesgo de reasignaciones geoméricamente imposibles. Por ello, uno de los retos centrales del trabajo consiste en encontrar un equilibrio entre persistencia temporal, asociación visual y plausibilidad espacial.

3.3. Coherencia de identidad y coherencia geométrica

En este trabajo se distinguen dos nociones que, aunque relacionadas, no son equivalentes: la coherencia de identidad y la coherencia geométrica.

La coherencia de identidad hace referencia a la capacidad del sistema para mantener el mismo identificador asignado a un jugador a lo largo del vídeo, evitando fragmentación excesiva, cambios de identidad y reutilización errónea de IDs. Esta dimensión suele reflejarse en métricas como IDF1, número de *ID switches*, fragmentaciones o

número total de identidades generadas por el sistema [1, 7]. En aplicaciones deportivas, esta propiedad es esencial para poder reconstruir trayectorias largas y extraer estadísticas fiables por jugador.

La coherencia geométrica, en cambio, se refiere a la plausibilidad espacial y temporal de las asociaciones realizadas por el tracker. Un sistema puede producir pocas identidades totales y, aun así, cometer errores físicamente incoherentes, por ejemplo reasignando un mismo ID a detecciones separadas por distancias incompatibles con el movimiento real del jugador entre fotogramas consecutivos o tras una breve desaparición. Este tipo de fallo no siempre queda suficientemente penalizado por las métricas MOT agregadas, especialmente cuando la reducción del número de IDs se logra a costa de fusiones demasiado agresivas.

La experiencia experimental de este TFG llevó precisamente a identificar que una parte del problema no era solo “cuántos IDs” producía el sistema, sino “cómo” se mantenían esos IDs. Por ello, la evaluación no se limita a métricas globales, sino que incorpora también inspección cualitativa de trayectorias, análisis de saltos espaciales y revisión de casos donde el tracker genera asociaciones que, aun reduciendo fragmentación, resultan visualmente inverosímiles. Esta distinción será clave para justificar más adelante la combinación de ReID online y *tracklet linking* offline.

3.4. Preguntas de investigación

A partir del contexto anterior, el trabajo se articula en torno a las siguientes preguntas de investigación:

- ¿Qué tracker ofrece el mejor punto de partida para seguimiento de jugadores en fútbol dentro de un esquema modular y reproducible?
- ¿Hasta qué punto el módulo de re-identificación aporta información útil en este dominio, y qué limitaciones presenta cuando la apariencia entre jugadores es altamente similar?
- ¿Es preferible integrar la señal ReID durante el proceso online de asociación o utilizarla, directa o indirectamente, en un postprocesado offline sobre tracklets ya formados?
- ¿Cómo afecta el dominio de entrenamiento del modelo ReID al rendimiento final del tracking, comparando un modelo genérico con modelos específicos para fútbol profesional y amateur?
- ¿Puede un postprocesado geométrico de *tracklet linking* corregir fragmentaciones e incoherencias espaciales que el tracker online no resuelve adecuadamente?

- ¿Qué combinación final de modelo ReID, configuración del tracker y linking ofrece el mejor equilibrio entre continuidad de identidad, reducción de fragmentación y plausibilidad geométrica?

Estas preguntas sintetizan la evolución real del proyecto: desde una comparación inicial de trackers hasta una investigación más precisa sobre cómo se representa, se utiliza y se corrige la identidad en el pipeline de seguimiento.

3.5. Hipótesis de trabajo

La primera hipótesis del trabajo es que ByteTrack constituye una base adecuada para el dominio del fútbol por su robustez como tracker *tracking-by-detection* y por su capacidad para aprovechar detecciones de baja confianza, algo especialmente útil en presencia de oclusiones [7]. Sin embargo, se plantea que su rendimiento en fútbol no depende solo del tracker en sí, sino de la forma en que se integra la señal de apariencia.

La segunda hipótesis es que el módulo ReID sí contiene información útil, pero su eficacia en fútbol queda condicionada por la similitud visual entre jugadores, la baja resolución de detalles locales y la variabilidad provocada por cámara y pose. En consecuencia, se espera que la utilidad del embedding dependa menos de su mera existencia y más de cómo se combine con criterios geométricos y temporales [6, 3].

La tercera hipótesis es que el postprocesado offline mediante *tracklet linking* puede corregir parte de los errores residuales del seguimiento online, especialmente aquellos relacionados con fragmentación e incoherencias espaciales. A diferencia de la asociación online, el linking opera sobre trayectorias ya observadas y puede aplicar criterios más conservadores y globales, lo que sugiere una complementariedad potencial entre ambos enfoques.

Por último, se plantea que la adaptación del modelo ReID al dominio puede mejorar la discriminación visual respecto a un baseline genérico, aunque dicha mejora no tiene por qué traducirse linealmente en mejores métricas globales si el tracker ya impone una parte importante de la dinámica de asociación. Por ello, el trabajo no asume de partida que “más especialización del ReID” implique necesariamente “mejor sistema final”, sino que somete esa relación a validación experimental.

4. Datos, materiales y entorno experimental

4.1. Datasets utilizados

4.2. Secuencias profesionales y amateur

4.3. Ground truth y pseudo-ground-truth

4.4. Entorno tecnológico

4.5. Organización reproducible de experimentos

5. Metodología general

5.1. Diseño iterativo del trabajo

El desarrollo del TFG se ha basado en una metodología iterativa, en línea con lo ya planteado en el anteproyecto. En lugar de fijar desde el inicio un único pipeline cerrado, el trabajo se estructuró como una secuencia de ciclos de diagnóstico, modificación, evaluación y revisión. Este enfoque resultaba especialmente adecuado para un problema como el seguimiento multiobjeto en fútbol, donde una parte relevante de las dificultades no se conoce con precisión hasta observar el comportamiento real de los modelos sobre secuencias concretas de vídeo.

La idea central de esta metodología fue avanzar desde niveles bajos de análisis hacia niveles más altos de integración. En una primera fase se compararon varios trackers y se identificaron sus fallos más evidentes. A continuación, se profundizó en el problema de identidad, primero mediante análisis visual y cuantitativo de trayectorias, y después mediante el estudio del módulo ReID de forma aislada. Sobre esa base, se plantearon dos líneas complementarias de mejora: la recalibración online de la asociación en ByteTrack y el postprocesado offline mediante *tracklet linking*. Finalmente, el trabajo se extendió al entrenamiento de modelos ReID específicos de dominio y a la construcción de una herramienta de apoyo para ejecutar el pipeline completo.

Este diseño iterativo también permitió incorporar de forma natural el feedback de las tutorías. A lo largo del proyecto, distintas decisiones metodológicas fueron reformuladas a partir de resultados intermedios: por ejemplo, la ampliación de métricas más allá de MOTA e IDF1, la revisión del papel del `track_buffer`, la necesidad de introducir análisis cualitativo para detectar incoherencias geométricas o el cambio de foco desde ajustes puramente online hacia el estudio del *tracklet linking* offline. En consecuencia, la metodología del trabajo no debe entenderse como una sucesión rígida de experimentos independientes, sino como un proceso acumulativo de validación y refinamiento.

5.2. Flujo general del pipeline

El pipeline general del TFG se articula en torno a una arquitectura modular, formada por cuatro grandes bloques: detección, tracking online, postprocesado offline y evaluación. Esta separación resulta útil tanto desde el punto de vista experimental como desde el punto de vista práctico, ya que permite aislar con claridad qué componente es responsable de cada mejora o degradación observada.

La Figura 1 resume el flujo metodológico seguido en el trabajo, diferenciando las fases online y offline, así como los elementos transversales de evaluación, análisis de errores y selección de configuraciones.




Figura 1: Pipeline metodológico del trabajo. El flujo experimental se organiza en dos grandes fases: una fase online, centrada en detección y tracking, y una fase offline, orientada al linking, la evaluación y el análisis de resultados. Además, el proceso incorpora elementos transversales como el registro de métricas, el análisis de errores, la generalización a múltiples secuencias y la selección de la configuración final.

En primer lugar, se parte de un detector de personas basado en YOLOX, integrado dentro del ecosistema de ByteTrack. Sobre esas detecciones se ejecuta el proceso de seguimiento online, utilizando ByteTrack como tracker base y, dependiendo de la configuración, incorporando o no un módulo ReID basado en embeddings OS-Net. Esta fase produce como salida un fichero de tracking en formato MOT, que constituye la representación estándar de las trayectorias generadas por el sistema.

En segundo lugar, opcionalmente se aplica un postprocesado offline de *tracklet linking*. A diferencia del tracking online, esta etapa no modifica la asociación frame a frame mientras el vídeo se procesa, sino que opera a posteriori sobre trayectorias ya cerradas. Su función es detectar fragmentos compatibles y fusionarlos cuando exista suficiente evidencia temporal, espacial y, en algunas variantes, visual. Este enfoque permite introducir restricciones más conservadoras y reducir ciertos errores geométricos residuales que no siempre quedan bien resueltos durante la asociación online.

En tercer lugar, el pipeline incluye una capa de visualización y análisis. Esta capa sirve para generar vídeo etiquetado, inspeccionar trayectorias y revisar de forma manual casos dudosos. En el contexto amateur, esta parte del flujo adquirió especial importancia, ya que fue necesario depurar salidas MOT para construir un *pseudo-ground truth* suficientemente consistente como para calcular métricas y preparar conjuntos de entrenamiento ReID en formato *gallery/query*.

Por último, el pipeline incorpora una etapa de evaluación cuantitativa y cualitativa. Cuando existe *ground truth*, se calculan métricas estándar de MOT; cuando no existe, la evaluación debe apoyarse con más fuerza en la inspección manual, la revisión de trayectorias y el análisis de errores estructurales. De este modo, la metodología combina reproducibilidad automatizada y análisis experto, evitando depender exclusivamente de un único tipo de evidencia.

5.3. Protocolo de evaluación cuantitativa

La evaluación cuantitativa se diseñó para comparar configuraciones de tracking y ReID de forma homogénea y reproducible. Para ello se utilizaron métricas estándar del campo MOT, en particular MOTA, IDF1, HOTA, número de *ID switches*, fragmentaciones y número total de identidades generadas por el sistema. Estas métricas ofrecen perspectivas complementarias: MOTA resume errores globales de detección y asociación; IDF1 mide consistencia de identidad; HOTA intenta equilibrar calidad de detección y asociación; mientras que *ID switches*, fragmentaciones y Total IDs resultan especialmente útiles para analizar la estabilidad de las trayectorias en vídeo deportivo [1, 7, 2].

A nivel de implementación, el protocolo se apoyó en dos motores principales: `motmetrics` y `trackeval`. Durante el desarrollo fue necesario revisar el evaluador para corregir problemas de alineación temporal entre el formato del *ground truth* y la salida del tracker, especialmente en relación con el indexado de frames. Esta revisión fue importante porque pequeñas inconsistencias en la correspondencia temporal pueden alterar sensiblemente las métricas de asociación y generar comparaciones engañosas entre configuraciones.

Además de las métricas estándar, en determinadas fases del trabajo se incorporaron medidas derivadas más específicas del dominio, como *ID switches* por minuto, *ID switches* por jugador y minuto o número total de IDs producidos en un clip. La razón para hacerlo fue que, en un contexto de seguimiento de futbolistas, no basta con optimizar métricas globales si al mismo tiempo el sistema produce una fragmentación excesiva o multiplica artificialmente el número de trayectorias asignadas. En otras palabras, la evaluación cuantitativa se orientó no solo a “maximizar una métrica”, sino a capturar mejor la continuidad real de identidad en escenarios deportivos.

Por último, conviene señalar que no todos los experimentos tienen el mismo estatus dentro de la memoria. Los resultados que se consideran definitivos son aquellos obtenidos con el protocolo ya estabilizado y comparables entre sí; en cambio, ciertos análisis exploratorios se conservaron únicamente como referencia metodológica o como prueba de hipótesis intermedias. Esta distinción se explicará con más detalle

en la Sección 5.5.

5.4. Protocolo de evaluación cualitativa

Aunque las métricas MOT son indispensables para comparar configuraciones, la experiencia acumulada durante el proyecto mostró que no son suficientes por sí solas para valorar la calidad real del seguimiento en fútbol. En particular, pueden existir trayectorias con pocas identidades totales o pocos cambios aparentes de ID que, sin embargo, contengan reasignaciones espacialmente imposibles o saltos visualmente inverosímiles. Por ello, se estableció desde fases tempranas un protocolo de evaluación cualitativa complementario.

Este protocolo se basó en la inspección manual de secuencias seleccionadas, la generación de vídeo etiquetado y la revisión de casos anómalos detectados cuantitativamente. Entre los fenómenos de interés destacaron: cruces entre jugadores, desaparición y reaparición de trayectorias, duplicación de identidades, teletransportación de un mismo ID entre zonas incompatibles del campo visual y asignaciones residuales sobre árbitros o jugadores distintos. Estos análisis permitieron identificar problemas que luego orientaron tanto la recalibración online de ReID como el diseño del linking offline.

La evaluación cualitativa no se utilizó como sustituto de las métricas, sino como criterio de validación estructural. Cuando dos configuraciones presentaban resultados cuantitativos cercanos, la plausibilidad geométrica y la coherencia visual de las trayectorias servían para interpretar mejor cuál de ellas resultaba más adecuada para el dominio. Esta idea fue particularmente importante en la elección final del pipeline, donde una pequeña degradación en alguna métrica global podía resultar aceptable si se corregían errores graves de consistencia espacial.

En el caso amateur, el análisis cualitativo tuvo además una función adicional: facilitar la curación manual de salidas MOT para construir un *pseudo-ground truth*. Los scripts desarrollados para revisión interactiva permitieron corregir IDs, eliminar duplicados y ajustar asociaciones dudosas, lo que posteriormente hizo posible tanto la evaluación sobre secuencias amateur como el entrenamiento de modelos ReID específicos.

5.5. Jerarquía de resultados: definitivos frente a exploratorios

Una parte importante de la solidez metodológica del trabajo consiste en distinguir entre resultados definitivos y resultados exploratorios. A lo largo del desarrollo se generaron numerosos informes intermedios, algunos de los cuales fueron útiles para

descartar hipótesis o para orientar decisiones posteriores, pero no todos deben recibir el mismo peso en la memoria final.

En esta memoria se consideran **resultados definitivos** aquellos obtenidos con el protocolo de evaluación ya estabilizado, sobre configuraciones comparables y con un objetivo claramente integrado en el pipeline final del TFG. En particular, esta categoría incluye la evaluación final de modelos ReID genéricos y específicos por dominio, así como los experimentos de aplicación de *tracklet linking* sobre dichos modelos. Estos bloques son los que sustentan la selección final del sistema.

Por el contrario, se consideran **resultados exploratorios** aquellos experimentos cuyo propósito principal fue contrastar hipótesis parciales durante el desarrollo, por ejemplo comprobar si el peso efectivo del ReID en la función de asociación era demasiado bajo o si una implementación alternativa de fusión alteraba sustancialmente el comportamiento del tracker. Aunque estos experimentos ofrecen información valiosa sobre la evolución del proyecto, no siempre son directamente comparables con la configuración final y, por tanto, se tratan en la memoria como evidencia secundaria o como apoyo metodológico.

Esta jerarquización cumple una doble función. En primer lugar, evita mezclar en el mismo plano resultados consolidados y pruebas de depuración o sensibilidad. En segundo lugar, permite contar de forma honesta el proceso real del TFG: no como una secuencia lineal sin incertidumbre, sino como una investigación aplicada en la que algunas líneas se confirmaron, otras se reformularon y otras se descartaron tras su validación experimental.

6. Comparativa inicial de trackers

Estructura del análisis

Objetivo del experimento

Comparar varios trackers representativos sobre una misma secuencia de fútbol para identificar cuál ofrecía el mejor punto de partida para el desarrollo posterior del TFG.

Material usado

Tablas de evaluación inicial sobre SNMOT-060, vídeos generados en las primeras pruebas y conversaciones con tutores sobre paradigmas de tracking tradicionales frente a métodos end-to-end.

Configuración

Secuencia SNMOT-060 de SoccerNet, aproximadamente 750 frames y 30 segundos de duración. Se evaluaron ByteTrack sin ReID, ByteTrack con ReID OSNet entrenado en SportsMOT, DeepEIoU con el mismo modelo ReID y MOTIP con pesos oficiales entrenados sobre SportsMOT. La evaluación se realizó con métricas MOT estándar y, posteriormente, con métricas ampliadas que incluían fragmentaciones y número total de IDs.

Resultados principales

ByteTrack sin ReID mostró el mejor equilibrio global en la comparación inicial, mientras que ByteTrack con ReID redujo cambios de identidad e IDs totales a costa de una ligera degradación en métricas globales. DeepEIoU presentó una fragmentación claramente superior y MOTIP mostró peor estabilidad global en este dominio.

Interpretación

La comparación inicial sugirió que el problema no era únicamente “usar o no usar ReID”, sino elegir una base modular suficientemente sólida sobre la que analizar después la asociación de identidad.

Limitaciones

Estas pruebas corresponden a una fase inicial del trabajo y todavía no incorporan ni la recalibración del evaluador ni las mejoras posteriores del

pipeline. Por tanto, deben leerse como una comparación exploratoria para selección de base, no como resultados finales del TFG.

Conclusión parcial

ByteTrack fue seleccionado como tracker base del trabajo por ofrecer el mejor equilibrio entre rendimiento, interpretabilidad y capacidad de modificación experimental.

6.1. Selección de trackers candidatos

La primera fase experimental del trabajo se planteó como una comparación entre varios trackers representativos de paradigmas distintos. El objetivo no era todavía optimizar un sistema final, sino determinar qué enfoque ofrecía una base más sólida para el dominio del fútbol. En las conversaciones iniciales con los tutores se planteó explícitamente comparar métodos tradicionales del paradigma *tracking-by-detection*, donde el tracking y la asociación pueden modularse por separado, frente a enfoques más integrados o *end-to-end*, como MOTIP, donde la identidad se aprende de forma más directa dentro del propio sistema.

Siguiendo este criterio, se seleccionaron cuatro configuraciones iniciales. La primera fue ByteTrack sin ReID, utilizada como línea base del paradigma modular. La segunda fue ByteTrack con un modelo ReID OSNet entrenado en SportsMOT, con el fin de comprobar si la incorporación de apariencia mejoraba la continuidad de identidad. La tercera fue DeepEIoU, también combinado con el mismo modelo ReID, como alternativa basada en un esquema de tracking deportivo con distinta política de asociación. Finalmente, se incluyó MOTIP como representante de un enfoque más reciente basado en transformers y predicción de identidad.

Esta selección resultó metodológicamente útil porque permitía responder simultáneamente a dos preguntas. Por un lado, si un tracker modular fuerte como ByteTrack era suficiente como base de trabajo. Por otro, si un método más integrado como MOTIP podía ofrecer ventajas en un escenario deportivo complejo sin necesidad de incorporar un módulo ReID explícito.

La Tabla 1 resume los resultados cuantitativos de la comparación inicial entre los trackers evaluados. Como puede observarse, ByteTrack sin ReID ofrecía ya un equilibrio muy competitivo entre métricas globales y estabilidad de identidad, mientras que la incorporación de ReID reducía notablemente los cambios de identidad y el número total de trayectorias. En cambio, DeepEIoU y MOTIP mostraban una fragmentación claramente superior, lo que justificó descartar ambos como base principal

del desarrollo posterior.

Tabla 1: Comparativa inicial de trackers sobre la secuencia SNMOT-060.

Método	MOTA	IDF1	ID Switches	Frag	Total IDs
ByteTrack sin ReID	80.7 %	75.6 %	41	119	62
ByteTrack + ReID (SportsMOT)	79.2 %	74.4 %	36	131	30
DeepEIoU + ReID (SportsMOT)	80.9 %	75.2 %	60	154	67
MOTIP	73.1 %	71.0 %	51	350	61

Además de las configuraciones recogidas en la Tabla 1, se realizaron otras pruebas preliminares adicionales durante la fase de selección inicial. Estas se incluyen en el Apéndice ?? para no sobrecargar la narrativa principal.

En conjunto, la tabla muestra que ByteTrack era la base más equilibrada para continuar el trabajo. Aunque DeepEIoU alcanzaba un valor de MOTA ligeramente superior, su número de cambios de identidad y fragmentaciones era mucho mayor. Por su parte, MOTIP presentaba un comportamiento claramente más inestable en este dominio. ByteTrack con ReID ya apuntaba, además, que la señal de apariencia podía aportar valor real al reducir los ID switches y compactar el número total de trayectorias.

6.2. ByteTrack

ByteTrack se utilizó como referencia principal de la familia *tracking-by-detection*. La razón de esta elección fue doble. En primer lugar, se trata de un tracker con muy buen rendimiento en la literatura reciente y con una filosofía especialmente interesante para escenarios con detecciones degradadas: en vez de descartar de manera temprana las cajas de baja confianza, intenta asociarlas también, recuperando instancias verdaderas que de otro modo fragmentarían la trayectoria. En segundo lugar, su implementación permite intervenir de forma relativamente sencilla en parámetros, lógica de asociación y acoplamiento con módulos ReID, lo que lo convertía en una base muy adecuada para un TFG centrado en análisis y modificación del pipeline.

En la comparación inicial, ByteTrack sin ReID obtuvo un rendimiento cuantitativo muy competitivo: 80.7 % de MOTA, 75.6 % de IDF1 y 41 ID switches. Además, en la tabla ampliada aparecía con 119 fragmentaciones y 62 IDs totales, lo que evidenciaba que, aunque la calidad global del tracking era alta, seguía existiendo un problema apreciable de fragmentación de identidades. Esta combinación de buen rendimiento base y margen claro de mejora fue precisamente una de las razones por las que

ByteTrack resultó especialmente atractivo como punto de partida.

Cuando se añadió un modelo OSNet entrenado en SportsMOT, ByteTrack pasó a 79.2 % de MOTA y 74.4 % de IDF1, pero redujo los ID switches de 41 a 36 y, sobre todo, redujo drásticamente los IDs totales de 62 a 30. Esta observación fue importante desde el principio, porque sugería que la señal ReID sí estaba aportando continuidad de identidad, aunque su integración no resultaba todavía óptima y generaba un trade-off entre compactación de identidades y calidad global del seguimiento.

6.3. DeepEIoU

DeepEIoU se incluyó como tracker alternativo dentro del conjunto de métodos probados en la fase inicial. Su interés residía en comprobar si un enfoque ya orientado a escenarios deportivos podía superar a ByteTrack al combinar asociación geométrica y apariencia. Para mantener la comparabilidad, se utilizó también un modelo OSNet entrenado en SportsMOT.

Los resultados cuantitativos mostraron que DeepEIoU alcanzaba 80.9 % de MOTA y 75.2 % de IDF1, es decir, un valor de MOTA ligeramente superior al de ByteTrack sin ReID. Sin embargo, esta aparente ventaja desaparecía al observar las métricas de identidad: 60 ID switches, 154 fragmentaciones y 67 IDs totales. En otras palabras, el tracker mantenía una calidad global aceptable en términos de detección y cobertura, pero lo hacía a costa de una estabilidad de identidad claramente peor.

Este comportamiento fue muy relevante para la selección del sistema base. La comparación mostraba que una métrica global ligeramente mejor no implicaba necesariamente un mejor tracker para el problema concreto del TFG. En un dominio donde la continuidad de identidad es un objetivo central, el número de cambios de ID y la fragmentación pesan más que una mejora marginal en MOTA. Por ello, aunque DeepEIoU se conservó como referencia comparativa, no se consideró la mejor base para el desarrollo posterior.

6.4. MOTIP

MOTIP se incorporó a la comparativa como representante de un paradigma distinto al de los trackers modulares clásicos. A diferencia de ByteTrack o DeepEIoU, no sigue la filosofía de *tracking-by-detection* con un módulo ReID acoplado, sino que plantea el seguimiento como un problema de predicción de identidad más integrado. Precisamente por ello resultaba interesante incluirlo en la fase inicial: permitía contrastar un método más reciente y cercano al paradigma *end-to-end* frente a los trackers tradicionales.

Sin embargo, los resultados cuantitativos iniciales fueron claramente peores que los de ByteTrack. MOTIP obtuvo 73.1 % de MOTA, 71.0 % de IDF1 y 51 ID switches. En la tabla ampliada, además, aparecía con 350 fragmentaciones y 61 IDs totales, cifras que reflejaban una inestabilidad notable de las trayectorias. Esta degradación no solo se observó en las métricas, sino también en el análisis visual posterior, donde se documentaron fenómenos de reciclaje de identidades, teletransportación por paneo de cámara y creación de IDs fantasma durante oclusiones y caídas de jugadores.

Desde el punto de vista metodológico, la inclusión de MOTIP fue, aun así, muy valiosa. Permitió comprobar que el paradigma alternativo era interesante desde un punto de vista conceptual, pero que en el dominio concreto del fútbol y bajo el protocolo experimental del TFG no constituía la mejor base para construir mejoras progresivas. Además, su menor modularidad lo hacía menos conveniente para un trabajo cuyo objetivo no era solo comparar resultados, sino intervenir explícitamente en la lógica de asociación e identidad.

6.5. Resultados iniciales y selección del tracker base

La comparación inicial permite extraer una conclusión clara. Si se observa únicamente MOTA, ByteTrack sin ReID y DeepEIoU ofrecen valores similares, e incluso DeepEIoU aparece ligeramente por encima. Sin embargo, al incorporar métricas de identidad y fragmentación, la diferencia entre métodos se vuelve mucho más clara. ByteTrack sin ReID logra el mejor equilibrio entre rendimiento global y estabilidad de identidad dentro de la comparación inicial, mientras que ByteTrack con ReID muestra ya una reducción notable de ID switches e IDs totales, aunque todavía con un trade-off no resuelto en MOTA e IDF1.

En cambio, DeepEIoU y MOTIP quedan por detrás cuando el criterio se desliza desde la mera cobertura global hacia la continuidad real de identidad. DeepEIoU incrementa fuertemente los cambios de ID y la fragmentación, y MOTIP presenta un comportamiento todavía más inestable, tanto cuantitativa como visualmente. Por ello, ambos métodos se conservaron como referencia comparativa, pero no como base principal del desarrollo posterior.

La decisión final de esta fase fue seleccionar ByteTrack como tracker base del TFG. Esta elección se apoyó en tres razones. En primer lugar, ofrecía el mejor equilibrio inicial entre métricas globales y continuidad de identidad. En segundo lugar, permitía experimentar de forma controlada con la integración de ReID, el ajuste de memoria temporal y la modificación de la función de asociación. Finalmente, su carácter modular lo hacía compatible con el tipo de contribución que se buscaba en este trabajo: no solo evaluar trackers existentes, sino analizar por qué fallan y proponer

mecanismos concretos para mejorar su comportamiento en fútbol.

7. Diagnóstico del problema de identidad

Estructura del análisis

Objetivo del experimento

Identificar de forma visual y cuantitativa los mecanismos principales de fallo en la continuidad de identidad de los trackers evaluados, con el fin de orientar las siguientes fases del trabajo.

Material usado

Diagnóstico visual de ByteTrack y MOTIP, vídeos comparativos, casos manualmente revisados y métricas ampliadas de fragmentación, número total de IDs y comportamiento temporal de las trayectorias.

Configuración

Secuencia SNMOT-060 de SoccerNet, aproximadamente 750 frames. Se analizaron visualmente casos representativos de ByteTrack y MOTIP en situaciones de solapamiento, caída de jugadores, cambios de cámara y desaparición/reaparición de trayectorias.

Resultados principales

Se identificaron tres mecanismos críticos en ByteTrack: intercambios de identidad en oclusiones múltiples, pérdida de seguimiento en cambios morfológicos extremos y teletransportación de IDs debido al exceso de memoria temporal. En MOTIP se observaron además reciclaje de IDs y creación repetida de identidades nuevas durante oclusiones complejas.

Interpretación

El problema de identidad no podía entenderse únicamente como una cuestión de métricas globales. Era necesario introducir análisis visual para distinguir entre fragmentación aceptable, cambios de identidad y asociaciones físicamente incoherentes.

Limitaciones

Este bloque corresponde todavía a una fase diagnóstica. Su objetivo no era comparar configuraciones finales, sino localizar patrones de fallo y derivar hipótesis de mejora para fases posteriores.

Conclusión parcial

El diagnóstico visual confirmó que la continuidad de identidad era el cuello de botella central del problema y justificó las siguientes líneas de trabajo: ajuste del `track_buffer`, análisis del módulo ReID, recalibración de la asociación online y diseño de un postprocesado offline mediante *tracklet linking*.

7.1. Análisis visual de fallos en ByteTrack

El diagnóstico visual de ByteTrack permitió identificar tres casuísticas críticas. La primera corresponde a situaciones de oclusión múltiple, donde varios jugadores convergen en una misma zona del campo y el tracker intercambia identidades al resolverse el cruce. El informe de diagnóstico resume este comportamiento como un fallo de asociación en el que ByteTrack fuerza una resolución predominantemente geométrica, incluso cuando el descriptor visual debería haber ayudado a distinguir a jugadores de equipos distintos.

La Figura 2 muestra la evolución completa de uno de estos casos. En estas imágenes, las cajas y etiquetas en verde con el prefijo GT corresponden a la anotación de referencia (*ground truth*), mientras que las cajas y etiquetas en rojo con el prefijo T representan la salida del tracker evaluado. En el frame 383, antes del solapamiento, las identidades todavía se mantienen de forma consistente. En el frame 413, varios jugadores convergen en una misma zona del campo y se produce la oclusión. Finalmente, en el frame 443, cuando el cruce ya se ha resuelto, se observa un intercambio de identidades entre jugadores que previamente estaban correctamente diferenciados. Este ejemplo es especialmente relevante porque no se trata solo de una pérdida temporal de seguimiento, sino de un *ID switch* entre trayectorias que deberían haberse mantenido separadas.





Figura 2: Caso de solapamiento múltiple en ByteTrack. La secuencia temporal muestra el estado previo al cruce, la fase de oclusión y la resolución final con intercambio de identidades. En particular, GT:4 pasa de estar asociado a T:11 a T:6, mientras que GT:16 pasa de T:6 a T:11, reflejando un *ID switch* inducido por el solapamiento.

La segunda casuística crítica aparece cuando un jugador cambia radicalmente de morfología, por ejemplo al caer al suelo. En este escenario, el detector deja de reconocerlo temporalmente, el tracker pierde la trayectoria y, al reaparecer, se genera un nuevo ID. El diagnóstico resume este caso como el del *jugador caído*, y lo asocia directamente a una caída del *confidence score* del detector y a la incapacidad del sistema para enlazar la trayectoria previa con la reaparición posterior.

La Figura 3 recoge este patrón. Al igual que en la figura anterior, las cajas y etiquetas en verde con el prefijo GT corresponden a la anotación de referencia (*ground truth*), mientras que las cajas y etiquetas en rojo con el prefijo T representan la salida del tracker evaluado. La secuencia muestra cómo, tras la caída del jugador, la detección se degrada y la asociación de identidad deja de ser consistente. Este tipo de fallo combina tres problemas en uno: pérdida de detección, reutilización errónea de identidad y fragmentación de trayectoria.



(a) Estado inicial antes de la pérdida completa de consistencia.



(b) El jugador permanece en el *ground truth*, pero la salida del tracker deja de ajustarse correctamente.



(c) Reaparición con asociación errónea y fragmentación de la trayectoria.

Figura 3: Caso del “jugador caído” en ByteTrack. Las etiquetas GT (verde) corresponden al *ground truth*, mientras que las etiquetas T (rojo) corresponden a la salida del tracker. La secuencia ilustra cómo un cambio brusco de pose degrada la detección y provoca pérdida de consistencia en la identidad seguida.

7.2. Casos críticos: oclusiones, jugador caído y teletransportación

La tercera casuística relevante identificada en ByteTrack fue la teletransportación de IDs en bordes de escena. Este fenómeno aparece cuando un jugador desaparece por un extremo del campo visual y, debido al paneo de cámara, otro jugador o incluso el portero aparece por el lado opuesto. Si la memoria temporal del tracker se mantiene demasiado tiempo, este puede forzar una asociación entre ambos eventos y asignar el mismo ID a detecciones espacialmente incompatibles. El informe de diagnóstico atribuye este comportamiento al uso de un `track_buffer` excesivamente alto, que mantiene vivas trayectorias ya incongruentes desde el punto de vista físico.

Este hallazgo fue importante porque introdujo una idea que reaparecerá en capítulos posteriores: una reducción artificial del número de IDs no siempre implica mejor tracking si se logra a costa de asociaciones geoméricamente imposibles. En otras palabras, la continuidad de identidad debía valorarse no solo en términos de cuántos IDs se producen, sino también en términos de plausibilidad espacial de las trayectorias resultantes.

En el caso de MOTIP, el fenómeno análogo se manifestaba de forma todavía más agresiva. La documentación visual recoge un caso en el que el mismo identificador

reaparece asociado sucesivamente a jugadores y posiciones incompatibles. Este comportamiento se interpreta como una forma extrema de reciclaje o teletransportación de identidades.

La Figura 4 ilustra este problema. A diferencia de las figuras anteriores, aquí se muestra directamente la salida del tracker, sin superposición de *ground truth*. La secuencia pone de manifiesto cómo el ID 0 aparece primero asociado a un jugador de campo, después se reutiliza sobre el portero y, posteriormente, vuelve a aparecer sobre otro jugador diferente. Esta falta de coherencia geométrica invalida la utilidad práctica de la trayectoria y fue una de las razones principales para descartar MOTIP como base del desarrollo posterior.




Figura 4: Caso de teletransportación y reciclaje de IDs en MOTIP. La secuencia temporal muestra cómo el mismo identificador se reutiliza sobre jugadores incompatibles, evidenciando una pérdida severa de coherencia espacial en el seguimiento.

7.3. Influencia del `track_buffer`

El diagnóstico visual mostró que el parámetro `track_buffer` tenía un papel decisivo en el comportamiento de ByteTrack. Un valor elevado permitía conservar trayectorias durante más tiempo y, en principio, parecía una estrategia razonable para evitar fragmentación. Sin embargo, en la práctica también favorecía que el sistema mantuviera vivas identidades incompatibles durante demasiados frames, provocando saltos espaciales y teletransportación en los bordes de escena.

Este resultado fue metodológicamente importante porque mostró que el problema no podía resolverse solo aumentando memoria temporal. Al contrario, una memoria demasiado larga podía generar una falsa sensación de continuidad mientras degradaba la coherencia física del seguimiento. Esta observación justificó que en fases

posteriores se revisara el papel del `track_buffer` y se buscara un equilibrio más fino entre persistencia de trayectoria y plausibilidad geométrica.

7.4. Heurísticas tempranas y sus limitaciones

A partir de los casos visuales identificados, se plantearon varias ideas de mejora temprana, entre ellas reducir el `track_buffer`, introducir una heurística de asociación espacial forzada y penalizar la creación de IDs nuevos cuando ya existieran muchas trayectorias activas en el campo. El diagnóstico ya anticipa explícitamente esta hoja de ruta, señalando la necesidad de atacar tanto la teletransportación de IDs como el caso del jugador caído mediante mecanismos más controlados de asociación.

No obstante, esta fase también dejó claro que las heurísticas aisladas no serían suficientes si no se entendía mejor el papel de la apariencia. En ByteTrack, algunos fallos sugerían que el sistema estaba priorizando en exceso la geometría frente al ReID en situaciones donde la apariencia debería haber ayudado. En MOTIP, por el contrario, la debilidad parecía estar en la propia consistencia del modelo de identidad cuando se enfrentaba a oclusiones severas y cambios de pose. Por ello, el siguiente paso lógico del trabajo no fue solo reajustar parámetros, sino analizar de manera más rigurosa el módulo ReID y su integración dentro del tracker.

Además, en MOTIP se observó otro patrón especialmente problemático: la creación progresiva de múltiples IDs fantasma durante una misma interacción compleja. A diferencia de un cambio aislado de identidad, aquí el sistema no solo pierde consistencia, sino que va introduciendo nuevos identificadores sobre una escena ya degradada, lo que provoca una fragmentación acumulativa.

Las Figuras 5 y 6 recogen este fenómeno. En ambos casos se muestra directamente la salida del tracker, sin superposición de *ground truth*. La primera secuencia ilustra el inicio del colapso, con la aparición progresiva de nuevos identificadores sobre una situación inicialmente más estable. La segunda secuencia muestra cómo el proceso continúa y termina generando nuevas identidades adicionales, evidenciando una pérdida severa de consistencia temporal.




Figura 5: Inicio de la creación de IDs fantasma en MOTIP. La secuencia muestra cómo una interacción entre jugadores deriva en la aparición progresiva de nuevas identidades no coherentes con la continuidad esperada de la escena.




Figura 6: Propagación del fenómeno de IDs fantasma en MOTIP. Tras el colapso inicial, el sistema continúa introduciendo nuevas identidades sobre la misma escena, lo que evidencia una pérdida severa de coherencia temporal y semántica.

7.5. Conclusión del diagnóstico

La Tabla 2 sintetiza los fallos principales detectados en esta fase diagnóstica. Su lectura conjunta confirma que el cuello de botella del problema no residía exclusivamente en detectar jugadores, sino en mantener identidades coherentes cuando la escena se volvía compleja.

Tabla 2: Resumen de fallos cualitativos identificados en la fase de diagnóstico.

Sistema	Fallo principal	Consecuencia
ByteTrack	Intercambio de IDs en oclusiones múltiples	Pérdida de continuidad entre jugadores distintos tras resolver el cruce
ByteTrack	Pérdida de trayectoria en el caso del jugador caído	Nuevo ID al reaparecer y apropiación del ID previo por otra trayectoria
ByteTrack	Teletransportación por exceso de memoria temporal	Asociación geoméricamente imposible entre extremos del campo
MOTIP	Reciclaje de IDs en paneos y reentradas	Reaparición del mismo ID sobre jugadores incompatibles
MOTIP	Creación de IDs fantasma en oclusiones severas	Explosión de fragmentación e inestabilidad de identidad

En conjunto, el diagnóstico visual y cuantitativo confirmó tres conclusiones de gran importancia para el resto del trabajo. En primer lugar, ByteTrack seguía siendo una base razonable, pero necesitaba ajustes porque su combinación de geometría, memoria y apariencia no resolvía adecuadamente ciertos casos críticos. En segundo lugar, MOTIP ofrecía un paradigma conceptualmente interesante, pero mostraba una inestabilidad demasiado alta en el dominio del fútbol. Finalmente, el problema central del TFG quedaba ya claramente delimitado: era necesario actuar sobre la continuidad de identidad, no solo sobre la detección, y hacerlo combinando análisis del ReID, recalibración online y postprocesado offline.

8. Análisis del módulo ReID

Estructura del análisis

Objetivo del experimento

Analizar el módulo ReID de forma aislada y estudiar qué información visual codifica realmente el embedding en el dominio del fútbol, con el fin de determinar si los problemas observados en tracking provienen del descriptor visual o de su integración dentro del tracker.

Material usado

Informe completo de análisis ReID, recortes representativos por identidad, métricas de separabilidad, figuras de ROC, histogramas, t-SNE, PCA, matriz de similitud, drift temporal, experimentos de atribución y comparación embedding puro frente a ByteTrack.

Configuración

Modelo OSNet x1.0 *fine-tuned* para deporte, secuencia SoccerNet SNMOT-060, 750 frames y 26 IDs del GT relevantes para el análisis. Se estudió el embedding tanto en aislamiento como en interacción con configuraciones de tracking.

Resultados principales

El embedding aislado presenta una separabilidad individual alta ($AUC \approx 0.903$), superior a la separabilidad por equipo ($AUC \approx 0.685$). Además, el análisis de atribución muestra que el color ayuda, pero no es la única señal; el dorsal aporta discriminación individual; y la parte inferior del cuerpo resulta, en esta secuencia, tan informativa o más que el torso. Sin embargo, cuando el tracker utiliza ReID online, la pureza de identidad y la separabilidad empeoran respecto a ByteTrack sin ReID.

Interpretación

El ReID no está “roto”, pero tampoco proporciona una firma individual lo bastante robusta como para ser usada indiscriminadamente en asociación online. Parte del problema parece residir en que el embedding captura información útil, aunque mezclada entre señales de identidad individual, equipo y estructura visual global.

Limitaciones

El análisis se centra en una secuencia concreta y en un modelo concreto. Sus conclusiones son muy informativas para el dominio del TFG, pero no deben extrapolarse automáticamente a cualquier escenario de ReID deportivo.

Conclusión parcial

El estudio del embedding justificó que la fase siguiente del trabajo se centrara no solo en usar ReID, sino en decidir cuándo y cómo debía intervenir dentro del pipeline de tracking.

8.1. Planteamiento del análisis

El objetivo de este capítulo es estudiar el modelo de re-identificación de forma aislada, antes de discutir su integración en el tracker. La motivación es clara: si la salida final del tracking presenta errores de identidad, es necesario distinguir si dichos errores proceden del propio embedding o de la forma en que el tracker lo utiliza. El informe experimental de ReID se diseñó precisamente para responder a esta cuestión mediante una secuencia de fases que van desde la auditoría del protocolo hasta la comparación entre embedding puro y tracking real.

Conceptualmente, el modelo ReID recibe un recorte de imagen de un jugador y produce una representación matemática fija de 512 dimensiones, denominada embedding. Si el modelo ha aprendido una firma visual útil, dos imágenes del mismo jugador deberían dar embeddings próximos, mientras que dos jugadores distintos deberían quedar más separados en el espacio de características. El propio informe introduce esta idea como una “huella digital visual” y la toma como base de todo el análisis posterior.

Este planteamiento es importante porque separa dos preguntas que, en una evaluación de tracking convencional, suelen quedar mezcladas: en primer lugar, si el embedding es realmente discriminativo a nivel visual; y, en segundo lugar, si el tracker sabe aprovechar esa información de forma adecuada durante el proceso de asociación.

8.2. Fase 0: auditoría y preparación del experimento

Antes de extraer conclusiones sobre el embedding, el informe dedica una fase específica a auditar el protocolo experimental. La idea central es garantizar que los

embeddings analizados proceden exclusivamente del modelo ReID y no están contaminados por el tracker. En el informe se comprueba, entre otros aspectos, que los ficheros de vídeo, anotaciones y checkpoint están disponibles, que el GT es parseable, que el vídeo y el GT se solapan suficientemente, que el preprocesado coincide con el usado en producción y que el código de análisis no importa módulos del tracker. El resultado global del informe es concluyente: la auditoría se considera superada y el experimento se interpreta como válido.

En esta fase también resulta muy útil mostrar una visión global de las identidades analizadas. Para ello, se incluye una rejilla con recortes representativos por ID, que sirve como soporte visual para entender qué jugadores se están comparando y cómo se realizó la asignación manual de equipos.




Figura 7: Recortes representativos por identidad utilizados en el análisis del embedding. Esta figura permite visualizar el conjunto de IDs considerados y sirve como base para la asignación manual de equipos a partir de la apariencia visual.

A partir de la inspección visual de estos recortes se realizó además una asignación manual de identidades a equipo, necesaria para los análisis de separabilidad por

equipo y para los experimentos de atribución. Esta asignación no se utilizó para modificar el tracking, sino únicamente como soporte analítico dentro del estudio del embedding. En particular, se distinguieron dos grupos de jugadores de campo en función de la equipación visible, mientras que árbitros y balón se excluyeron de este análisis específico.

Tabla 3: Asignación manual de identidades a equipo para el análisis del embedding.

Grupo	IDs incluidos
Equipo A (camiseta blanca con detalles azules)	1, 2, 7, 11, 12, 13, 15, 16, 19, 20, 21
Equipo B (camiseta verde)	3, 4, 5, 6, 8, 9, 10, 23, 24
Excluidos del análisis de equipo	14, 17, 18, 22, 25, 26

Conviene señalar que el Equipo B incluye únicamente a los jugadores de campo identificables por camiseta verde. El portero, al presentar una equipación distinta, no se incorpora como parte homogénea de ese grupo en el análisis específico por equipo.

Tabla 4: Resumen de la auditoría del experimento ReID.

Comprobación	Resultado
Existencia y accesibilidad de vídeo, GT y check-point	PASS
Anotaciones GT válidas y parseables	PASS
Solapamiento suficiente entre vídeo y GT	PASS
Preprocesado idéntico al del pipeline de producción	PASS
Código de análisis aislado del tracker	PASS
Test de repetibilidad del embedding	PASS
Escala / norma del embedding documentada	PASS

8.3. Fase 1: validación del embedding puro

La primera pregunta importante es si el embedding puro, sin intervención del tracker, discrimina realmente jugadores. El informe responde afirmativamente: la curva ROC y las métricas de separabilidad por jugador muestran que el modelo aislado alcanza un AUC de aproximadamente 0.903, interpretado como una discriminación alta para este dominio. En la narrativa del informe, esto se traduce en una conclusión clara: la

“huella digital visual” generada por OSNet es suficientemente discriminativa como para ser útil en un sistema de tracking, al menos cuando se la estudia aislada del proceso de asociación.




Figura 8: Curva ROC del embedding puro para discriminación por jugador. Una curva próxima a la esquina superior izquierda indica una buena capacidad discriminativa. En el informe, el área bajo la curva se sitúa en torno a 0.903.


Aun así, el análisis no se limita a identidad individual. El informe estudia también la separabilidad por equipo y muestra que el embedding distingue mejor entre jugadores concretos que entre equipos. En particular, la separabilidad por equipo se describe como moderada, con un AUC de aproximadamente 0.685, claramente inferior al AUC por jugador. Esto sugiere que el modelo no se basa únicamente en el color de la camiseta, aunque sí retiene cierta información global de equipo.

Tabla 5: Separabilidad del embedding puro por identidad individual y por equipo.


Medida	Jugador	Equipo
AUC	0.903	0.685
Interpretación	Alta separabilidad	Separabilidad moderada

La Tabla 5 deja ya una primera lectura importante: el embedding contiene una señal de equipo detectable, pero considerablemente más débil que la señal de identidad individual. Por tanto, el descriptor visual no puede interpretarse simplemente como un clasificador de color de camiseta, ni tampoco como una firma individual perfectamente estable y separada.

Para reforzar esta interpretación, el capítulo se apoya también en histogramas de distancia, matrices de similitud y proyecciones de alta dimensión reducidas a dos dimensiones. Estas visualizaciones no deben interpretarse como prueba definitiva por sí solas, pero sí son muy útiles para mostrar la estructura general del espacio de embeddings.



(a) Distribución de distancias por identidad.



(b) Distribución de distancias por equipo.

Figura 9: Histogramas de distancias en el espacio de embeddings. La separación entre distribuciones es más clara en el caso de la identidad individual que en el caso del equipo.

8.4. Estructura del espacio de embeddings: t-SNE, PCA y similitud

Las visualizaciones en t-SNE y PCA permiten profundizar en la estructura del embedding. Cuando los puntos se colorean por identidad, el espacio aparece relativamente disperso, mientras que al colorearlos por equipo se aprecia cierta estructura global, aunque no completamente separada. Esta observación es coherente con la conclusión previa: el embedding contiene información de identidad útil, pero también una componente importante de apariencia global compartida entre miembros del mismo equipo.




Figura 10: Proyecciones t-SNE del embedding. La estructura por equipo resulta más visible que la separación limpia por jugador individual.




Figura 11: Proyecciones PCA del embedding. Aunque la reducción lineal no separa perfectamente a los jugadores, sí permite observar agrupaciones parciales relacionadas con la apariencia global de equipo.




Figura 12: Varianza explicada acumulada por PCA. Esta figura ayuda a valorar cuánta estructura útil del embedding se conserva en las primeras componentes principales.

La matriz de similitud coseno entre identidades medias refuerza esta lectura. Si el

embedding separara perfectamente a los jugadores, cabría esperar un patrón claramente bloque-diagonal con similitudes bajas fuera de la diagonal. Sin embargo, la matriz presenta similitudes elevadas entre varias identidades, lo que ya anticipa el riesgo de fusiones erróneas cuando el descriptor se utiliza como señal fuerte de asociación. Esta figura es particularmente útil para conectar este capítulo con el siguiente, donde se discutirá la integración online del ReID dentro de ByteTrack.




Figura 13: Matriz de similitud coseno entre embeddings medios por identidad. Las similitudes elevadas entre distintos jugadores reflejan que el espacio de embeddings no está completamente separado a nivel individual.

8.5. Estabilidad temporal del embedding

Una cuestión distinta, pero igualmente importante, es la estabilidad temporal. No basta con que dos jugadores diferentes estén algo separados; además, una misma identidad debería mantener una representación relativamente estable a lo largo del tiempo. El informe señala explícitamente que la distancia al embedding inicial raramente supera 0.25–0.30, lo que interpreta como una buena estabilidad frame a frame.




Figura 14: Evolución temporal de la distancia respecto al embedding inicial. En general, las curvas se mantienen bajas, lo que indica una estabilidad temporal razonable del descriptor visual para una misma trayectoria.

Este resultado introduce un matiz importante. El embedding no parece ser caótico ni totalmente inestable. De hecho, visto en aislamiento, es relativamente consistente en el tiempo. El problema, por tanto, no es simplemente que el ReID “cambie demasiado de un frame a otro”, sino que esa estabilidad temporal convive con una separabilidad imperfecta entre distintas identidades del mismo dominio.

8.6. Fase 2: ¿qué información visual usa el modelo?

Una de las partes más interesantes del informe es la fase de atribución, en la que se modifica de forma controlada el contenido visual de los recortes para observar qué señales afectan más al embedding. Los experimentos considerados son seis: escala de grises, blur suave, blur fuerte, solo torso, solo piernas y combinación de grises más blur. El propio informe presenta esta fase como una forma de preguntar en qué se fija realmente el modelo: color, dorsal, forma corporal o estructura general.




Figura 15: Resumen visual de los experimentos de atribución. Las barras comparan la separabilidad por jugador y por equipo tras aplicar perturbaciones controladas a los recortes.

Tabla 6: Resultados de los experimentos de atribución del embedding.

Experimento	AUC jugador	Δ AUC jugador	AUC equipo	Δ AUC equipo
Baseline (original)	0.904	—	0.684	—
Escala de grises	0.853	-5.6 %	0.659	-3.7 %
Blur suave (k=15)	0.891	-1.4 %	0.700	+2.3 %
Blur fuerte (k=31)	0.855	-5.7 %	0.664	-2.9 %
Solo torso	0.862	-4.6 %	0.652	-4.7 %
Solo piernas	0.877	-3.0 %	0.656	-4.1 %
Grises + blur	0.842	-6.9 %	0.685	≈ 0 %

De esta fase surgen cuatro conclusiones especialmente interesantes. En primer lugar, el color importa, pero no es la única señal: al pasar a escala de grises, el AUC por jugador cae de 0.904 a 0.853, una degradación significativa, aunque el modelo sigue funcionando razonablemente bien. En segundo lugar, el blur suave apenas perjudica la discriminación por jugador y, de forma sorprendente, mejora la discriminación por equipo, lo que sugiere que el dorsal y los logos pueden introducir ruido cuando se intenta distinguir uniformidad de equipo. En tercer lugar, el análisis por partes del cuerpo muestra que las piernas son, en esta secuencia, ligeramente más informativas que el torso. Finalmente, la combinación de grises y blur apenas altera el AUC por equipo, lo que apunta a que la señal de equipo no depende exclusivamente del color.

Estas observaciones son muy valiosas para el TFG porque permiten pasar de una interpretación vaga del ReID a una interpretación más concreta: el modelo sí usa color, pero también forma y textura estructural; el dorsal aporta discriminación individual, aunque puede perjudicar una agrupación por equipo; y la región inferior del cuerpo contiene más información útil de la que intuitivamente podría esperarse. Todo ello refuerza la idea de que el embedding no es una señal simple, sino una

mezcla de pistas visuales con relevancia desigual según el tipo de decisión que se quiera tomar.

8.7. Fase 3: comparación entre embedding puro y tracker

La última fase del informe introduce una comparación especialmente importante: no basta con saber si el embedding puro funciona razonablemente bien, sino que hay que comprobar si el tracker sabe aprovecharlo. El informe lo plantea de forma explícita mediante tres configuraciones: referencia con embedding puro sobre GT, ByteTrack sin ReID y ByteTrack con ReID activado.




Figura 16: Comparación entre embedding puro y configuraciones de tracking. La figura resume la diferencia entre la separabilidad intrínseca del modelo y la forma en que el tracker explota —o degrada— esa señal visual.

Tabla 7: Comparación entre embedding puro y uso del embedding dentro del tracker.

Configuración	d'	AUC	Pureza de ID	Cambios de ID
Referencia: embedding puro (GT)	1.794	0.896	1.000	0
ByteTrack solo IoU	1.860	0.902	0.978	11
ByteTrack con ReID	1.146	0.793	0.903	13

El resultado es muy revelador: ByteTrack sin ReID mantiene una pureza de identidad muy alta y una separabilidad incluso ligeramente mejor que la referencia aislada, mientras que ByteTrack con ReID activado empeora tanto en separabilidad como en pureza y además incrementa los cambios de identidad. El propio informe lo interpreta como una evidencia de que el tracker no está explotando bien los embeddings, sino que, en esta configuración, está introduciendo confusión adicional.

8.8. Discusión: qué demuestra realmente este estudio

En conjunto, el estudio del embedding ReID demuestra varias cosas a la vez. Primero, que el modelo no está trivialmente roto: aislado del tracker, discrimina jugadores individuales con una calidad razonable y mantiene una estabilidad temporal aceptable. Segundo, que la información que codifica es compleja y no puede reducirse únicamente al color de la camiseta o al dorsal. En particular, la separabilidad por equipo es solo moderada, y los experimentos de atribución sugieren que la señal de equipo no depende exclusivamente del color, sino también de propiedades más globales como la forma, la textura estructural o la configuración visual general del recorte. En consecuencia, el embedding sí capta cierta información de equipo, pero no de forma lo bastante fuerte y limpia como para constituir por sí sola una señal robusta de asociación.

Tercero, una buena capacidad discriminativa del embedding puro no garantiza automáticamente una buena integración dentro del pipeline de tracking. Esta última conclusión es probablemente la más importante de todo el capítulo. El análisis del ReID no llevó a descartarlo como tecnología, sino a reformular su papel dentro del sistema. Si el embedding aislado contiene información útil, pero la configuración online de ByteTrack con ReID la aprovecha mal, entonces el siguiente paso lógico no es abandonar el módulo, sino estudiar cómo recalibrar su integración. Precisamente esa será la tarea del capítulo siguiente.

9. Integración online de ReID en ByteTrack

Estructura del análisis

Objetivo del experimento

Estudiar distintas estrategias de integración online del módulo ReID en ByteTrack y evaluar si la señal de apariencia mejora realmente la continuidad de identidad o, por el contrario, introduce ruido adicional en el proceso de asociación.

Material usado

Informe de recalibración del ReID en ByteTrack, comparación de las configuraciones v0, v1, v2 y v3 sobre SNMOT-060, e informe cualitativo específico de la configuración v1 con ejemplos visuales de teletransportes, saltos espaciales y gaps internos.

Configuración

Secuencia SNMOT-060 de SoccerNet. Se compararon cuatro variantes: ByteTrack sin ReID (v0), integración original del ReID (v1), división de asociación con tracks activos por IoU y tracks perdidos por IoU+ReID (v2), y la misma división añadiendo una guardia IoU y reducción del peso base del ReID (v3).

Resultados principales

La integración original del ReID (v1) redujo los ID switches de 45 a 36 y los IDs totales de 62 a 30, pero empeoró MOTA (80.7% $\rightarrow$ 79.4%) y aumentó las fragmentaciones (119 $\rightarrow$ 133). La configuración v2 resultó claramente degradada. La configuración v3 recuperó MOTA hasta 80.8% y redujo los ID switches a 41, aunque quedó por detrás de v1 en compactación de identidades (49 IDs frente a 30).

Interpretación

El ReID online sí puede aportar valor, pero su efecto depende fuertemente de cómo se combine con la señal geométrica. Aplicarlo de forma indiscriminada sobre todos los tracks degrada el tracker; utilizarlo de forma más selectiva mejora la estabilidad global, aunque no siempre maximiza la compactación de identidades.

Limitaciones

Este bloque se centra en integración online sobre una secuencia concreta. La evaluación muestra el compromiso entre continuidad de identidad y estabilidad geométrica, pero no agota todavía el problema, ya que parte de los errores residuales siguen requiriendo intervención offline.

Conclusión parcial

La integración online del ReID no debe tratarse como un bloque todo-o-nada. Los resultados justifican tanto la recalibración del *matching* como la necesidad de un postprocesado posterior para corregir los errores espaciales que el tracker online aún no resuelve.

9.1. Motivación de la recalibración online

Tras el análisis del capítulo anterior, el problema dejó de formularse como una pregunta binaria del tipo “usar ReID” frente a “no usar ReID”. El embedding aislado mostraba capacidad discriminativa razonable, pero también limitaciones importantes: señal de equipo solo moderada, separabilidad imperfecta entre identidades del mismo dominio y riesgo de similitudes espurias entre jugadores visualmente parecidos. Por tanto, la cuestión relevante pasó a ser otra: *cómo* debía intervenir el ReID dentro del proceso de asociación online de ByteTrack.

El punto de partida del experimento de recalibración fue una hipótesis muy concreta: el problema no era necesariamente el modelo ReID en sí, sino el hecho de aplicarlo de forma indiscriminada sobre todos los tracks, incluso cuando la evidencia geométrica ya era suficiente para decidir correctamente. Dicho de forma simple, si el tracker “sabía perfectamente dónde estaba un jugador” a través del IoU y de la continuidad temporal, añadir apariencia podía introducir más ruido que información.

Desde esta perspectiva, la recalibración online se diseñó para responder a tres preguntas. En primer lugar, qué rendimiento ofrecía ByteTrack sin ayuda explícita de apariencia. En segundo lugar, qué ocurría al introducir el ReID en su forma original. En tercer lugar, si era posible obtener una versión más selectiva y prudente de esa integración, restringiendo el uso de la apariencia a aquellos casos donde verdaderamente pudiera aportar valor.

9.2. Diseño de las configuraciones v0, v1, v2 y v3

Con el fin de estudiar el impacto real del ReID online en ByteTrack, se definieron cuatro configuraciones progresivas. La idea no era únicamente comparar “con ReID” frente a “sin ReID”, sino analizar distintas formas de introducir la señal de apariencia dentro del proceso de asociación.

La configuración v0 corresponde a la línea base del tracker, es decir, ByteTrack sin integración explícita de ReID. En este caso, la asociación se apoya esencialmente en información geométrica y temporal, por lo que v0 actúa como referencia para medir hasta qué punto la apariencia añade valor real al sistema.

La configuración v1 introduce el módulo ReID en su forma original, es decir, incorporando la señal de apariencia dentro del *matching* online sin distinguir entre tipos de track ni entre situaciones fáciles o ambiguas. Esta variante representa el uso más directo del embedding visual y permite comprobar si la simple incorporación del ReID mejora la continuidad de identidad.

La configuración v2 surge como una primera recalibración. En ella se separa la lógica de asociación entre tracks activos y tracks perdidos: los tracks activos se asocian por IoU, mientras que los tracks perdidos se resuelven mediante una combinación de IoU y ReID. La hipótesis detrás de esta variante es que la apariencia debería ser más útil en reidentificación de trayectorias perdidas que en seguimiento local de objetos ya bien posicionados.

La configuración v3 introduce una segunda recalibración sobre v2. Además del esquema de asociación dividida, se añade una guardia geométrica basada en IoU y se reduce el peso relativo del ReID. El objetivo es convertir la señal visual en un criterio auxiliar y conservador, evitando que domine la decisión cuando la evidencia espacial ya es suficientemente fuerte.

Desde un punto de vista experimental, estas cuatro configuraciones representan una progresión lógica. v0 responde a la pregunta de qué puede hacer ByteTrack por sí solo; v1 mide el efecto de añadir ReID sin restricciones; v2 comprueba si limitar su uso a tracks perdidos mejora el comportamiento; y v3 evalúa si una integración más prudente consigue equilibrar continuidad de identidad y estabilidad global del seguimiento.

9.3. Por qué la guardia IoU de v3 no duplica el IoU nativo de ByteTrack

Un punto importante de esta variante es que la guardia IoU introducida en v3 no debe interpretarse como una duplicación redundante del IoU que ByteTrack ya emplea de serie. ByteTrack utiliza IoU como parte de su mecanismo estándar de asociación entre tracks y detecciones, es decir, como una señal geométrica dentro del proceso ordinario de *matching*. En ese contexto, el IoU responde a una pregunta del tipo: *qué detección encaja mejor con este track en el estado actual del seguimiento*.

En cambio, la guardia IoU de v3 cumple una función distinta. No se introduce para volver a calcular el mismo emparejamiento geométrico, sino para limitar la influencia del ReID en casos donde la continuidad espacial es insuficiente o ambigua. Dicho de otro modo, el IoU nativo de ByteTrack participa en el coste de asociación base, mientras que el IoU añadido en v3 actúa como una condición de plausibilidad espacial sobre el uso de la apariencia.

Esta distinción es relevante porque al introducir ReID aparece un modo de fallo nuevo que ByteTrack puro no sufre con la misma intensidad: asociaciones con alta similitud visual pero baja coherencia geométrica. Es exactamente el tipo de error que se observó en teletransportes de identidad y reapariciones imposibles entre extremos opuestos del campo. En esos casos, el problema ya no es simplemente “qué detección solapa mejor”, sino si resulta aceptable permitir que la similitud visual intervenga en una reasociación espacialmente débil.

Por tanto, v3 no “reaplica IoU” para hacer otra vez lo mismo, sino que reutiliza la información geométrica con un papel diferente: no como criterio de asociación principal, sino como veto o guardia sobre la rama de apariencia. Esta diferencia funcional es la que justifica que la variante tenga sentido incluso cuando ByteTrack ya incorpora IoU en su lógica base.

9.4. Resultados cuantitativos de la recalibración

La Tabla 8 resume los resultados de las cuatro configuraciones comparadas en el experimento de recalibración. v0 actúa como línea base nativa de ByteTrack, v1 como integración original del ReID, v2 como primera propuesta de *split* de asociación y v3 como versión recalibrada con guardia IoU.

Tabla 8: Comparación de configuraciones online de ReID en ByteTrack sobre SNMOT-060.

Config.	HOTA	MOTA	IDF1	ID Sw.	Frag.	IDs	IDSW/min
v0 – Sin ReID	60.0 %	80.7 %	75.6 %	45	119	62	90
v1 – ReID original	59.3 %	79.4 %	75.6 %	36	133	30	72
v2 – ReID split	56.6 %	79.4 %	72.0 %	72	160	31	144
v3 – ReID split + guardia	58.5 %	80.8 %	73.9 %	41	135	49	82

Los resultados permiten extraer varias observaciones claras. En primer lugar, **v1** es la configuración que más reduce los IDs totales y también la que más baja los *ID switches*, lo que confirma que el ReID online sí puede contribuir a la continuidad de identidad. En segundo lugar, **v2** demuestra que no basta con “mover” el ReID a los tracks perdidos si se mantiene un peso demasiado alto: su comportamiento es claramente degradado, con 72 *ID switches* y 160 fragmentaciones, muy por encima de cualquier otra configuración. En tercer lugar, **v3** recupera la estabilidad global del tracker: alcanza la mejor MOTA (80.8 %) y reduce los *ID switches* a 41, aunque no compacta identidades tan agresivamente como **v1**.

Estos resultados son especialmente importantes porque muestran que el ReID online no se comporta como una mejora monótona. Puede reducir el número de identidades, pero también empeorar otras métricas si se utiliza sin control. En consecuencia, el análisis no debe plantearse como una comparación simple entre “con ReID” y “sin ReID”, sino como una comparación entre distintas políticas de integración de la apariencia.

9.5. Lectura funcional del trade-off

Desde una perspectiva funcional, cada configuración ocupa un papel distinto dentro del experimento. **v0** representa la robustez geométrica pura de ByteTrack y constituye la referencia frente a la que medir cualquier ganancia o degradación causada por la apariencia. **v1** demuestra que el ReID puede compactar identidades y reducir cambios de ID de manera notable, pero también deja claro que esa compactación no garantiza por sí sola una mejora homogénea del tracking.

v2 cumple un papel especialmente útil desde el punto de vista científico, aunque sus resultados sean malos. Actúa como contraejemplo experimental: muestra que la idea de “usar ReID solo en tracks perdidos” no funciona automáticamente si la apariencia sigue teniendo demasiado peso y no se controla geométricamente. Es decir, no basta con desplazar el ReID a un subconjunto del problema; también hay que moderar cómo influye en la decisión final.

v3, por su parte, puede interpretarse como la variante más equilibrada del experimento online. No logra la compactación extrema de v1, pero recupera estabilidad global y evita parte de la degradación introducida por el uso agresivo de apariencia. En este sentido, v3 es la mejor evidencia de que el ReID online solo resulta útil cuando se trata como una pista auxiliar y no como una señal dominante.

9.6. Evaluación cualitativa de v1

Aunque la lectura global del experimento sugiere que v3 es una configuración más equilibrada en términos agregados, la evaluación cualitativa de v1 muestra por qué esta variante seguía siendo extremadamente relevante para el TFG. El informe cualitativo específico de v1 concluye que el tracking tiene una calidad general aceptable y lo considera explícitamente un candidato a *tracklet linking*, precisamente porque compacta bien identidades pero deja errores espaciales residuales que parecen corregibles a posteriori.

Las métricas cualitativas del informe son muy ilustrativas: v1 produce 30 IDs únicos, un *fill rate* medio del 89.5 %, 17 saltos espaciales críticos, 30 *gaps* internos, 5 *gaps* con error confirmado, 17 IDs con *fill rate* superior al 95 % y 10 IDs con dos o más *gaps*. En otras palabras, la configuración consigue trayectorias largas y relativamente continuas, pero no evita todavía reasignaciones geométricamente imposibles ni reapariciones incoherentes.

Tabla 9: Resumen cualitativo de la configuración v1 (ReID online original).

Indicador	Valor
IDs únicos	30
Fill rate medio	89.5 %
Saltos >100 px/frame	17
Gaps internos (>2f)	30
Gaps con error confirmado	5
IDs con fill ≥ 95 %	17
IDs con ≥ 2 gaps	10

La Figura 17 resume visualmente el comportamiento general de v1 a lo largo de la secuencia. Se han escogido tres frames representativos del inicio, la parte media y el final del clip para mostrar que el tracker mantiene pocas identidades totales y trayectorias largas durante buena parte del vídeo. Esta continuidad global explica por qué v1 era una configuración tan atractiva pese a sus errores residuales.



(a) Frame inicial.

(b) Zona media del clip.


(c) Frame final.

Figura 17: Vista general del comportamiento cualitativo de **v1**. La configuración mantiene trayectorias largas y un número reducido de identidades, lo que la convierte en una buena candidata para postprocesado offline.

El valor de esta evaluación cualitativa es doble. Por un lado, confirma que **v1** no es una configuración desastrosa ni arbitraria, sino un sistema que efectivamente logra compactar la identidad de forma visible. Por otro, evidencia que esa compactación todavía viene acompañada de errores espaciales graves, como saltos imposibles entre extremos del campo o reconexiones erróneas tras *gaps* internos. Esta lectura es muy importante porque anticipa la lógica del capítulo siguiente: si **v1** produce *tracklets* largos pero con puntos de ruptura muy localizados, entonces el postprocesado offline puede tener sentido como mecanismo corrector.

9.7. Errores espaciales representativos

Uno de los errores más graves detectados en **v1** es el teletransporte de identidad entre extremos opuestos de la pantalla. El HTML cualitativo lo describe explícitamente como un error clásico de ReID online: un jugador desaparece por un lado del campo y otro distinto reaparece por el lado contrario, pero ambos quedan asociados bajo el mismo ID por tener una apariencia similar. En el caso seleccionado para la Figura 18, el ID 17 recorre implícitamente 1902.1 píxeles en solo 24 frames, algo físicamente incompatible con el movimiento real de un mismo jugador dentro del clip.



(a) Desaparición en frame 467.

(b) Reaparición en frame 491.

Figura 18: Ejemplo de teletransporte de identidad en **v1**. El mismo ID 17 se reutiliza tras una desaparición en una posición incompatible con la continuidad geométrica esperable.

Este tipo de fallo es especialmente relevante para el TFG porque muestra una limitación fundamental del enfoque online: aunque el ReID ayude a compactar identidades, también puede forzar reasignaciones imposibles cuando la evidencia visual se impone a la coherencia espacial. Dicho de otro modo, la reducción de IDs totales puede venir acompañada de asociaciones semánticamente incorrectas.

Un segundo tipo de error importante son los *gaps* internos mal resueltos. El HTML local marca algunos de ellos como errores confirmados y señala explícitamente que no deben reconectarse durante el *tracklet linking*. La Figura 19 muestra uno de los casos más claros: el ID 14 desaparece y reaparece más tarde sobre un árbitro. Aquí el problema ya no es solo un salto espacial, sino una ruptura semántica directa de la trayectoria.



(a) Última detección válida en frame 537.



(b) Reaparición errónea en frame 605.

Figura 19: Ejemplo de *gap* con error confirmado en v1. El mismo ID reaparece sobre un árbitro, por lo que la trayectoria no debe reconectarse como si se tratara del mismo jugador.

Estos ejemplos justifican una idea muy importante para el resto del trabajo: el objetivo no es únicamente reducir IDs o cerrar *gaps*, sino hacerlo preservando coherencia geométrica y semántica. Un sistema que compacta trayectorias a costa de unir jugadores distintos no resulta útil para el análisis final.

9.8. Conclusión del enfoque online y transición al linking

El principal resultado de este capítulo es que la integración online del ReID obliga a aceptar un compromiso entre varios objetivos parcialmente incompatibles. v1 maximiza la compactación de identidades y reduce de forma muy fuerte el número total de IDs, pero lo hace sacrificando parte de la estabilidad global del tracker y manteniendo errores espaciales críticos. v3, en cambio, protege mejor la calidad global del seguimiento y contiene mejor el ruido del ReID, pero ya no logra la misma compresión de identidades. v2 muestra de forma negativa lo que ocurre cuando se introduce el ReID con una política todavía demasiado agresiva.

Por tanto, no existe una única conclusión simplista del tipo “el ReID online mejora” o “el ReID online empeora”. Lo que muestran estos experimentos es algo más preciso: el ReID online puede ser útil, pero solo si se controla cuidadosamente su ámbito de actuación y su peso relativo frente a la señal geométrica. Además, incluso en su mejor forma, el tracker online sigue dejando errores que no se resuelven bien frame a frame y que resultan más adecuados para un tratamiento posterior sobre *tracklets* ya formados.

Desde esta perspectiva, el papel de **v1** dentro del TFG es especialmente interesante. No es la configuración más equilibrada en todas las métricas, pero sí una de las más informativas, porque pone de manifiesto tanto el potencial como las limitaciones del ReID online. Precisamente por ello, el siguiente paso lógico no es cerrar aquí la discusión, sino explorar si un postprocesado offline puede aprovechar la continuidad que **v1** consigue y corregir, al mismo tiempo, sus incoherencias espaciales más graves.

10. Postprocesado offline mediante tracklet linking

Estructura del análisis

Objetivo del experimento

Diseñar y evaluar un postprocesado offline basado en *tracklet linking*, con el fin de reducir fragmentación e incoherencias de identidad sin modificar el funcionamiento interno del tracker online.

Material usado

Informe de experimentos de linking offline sobre SNMOT-060, comparativa unificada entre enfoques online y offline, resultados de generalización a múltiples secuencias y documentación exploratoria utilizada para formular hipótesis de trabajo.

Configuración

El pipeline se aplicó inicialmente sobre la salida **v0** de ByteTrack sin ReID y, en una fase posterior, sobre variantes derivadas de **v1**. El linking utiliza información temporal, espacial y, en algunas variantes, visual, para proponer fusiones entre tracklets.

Resultados principales

El linking offline redujo de forma consistente el número total de IDs y los *ID switches* por minuto, alargando la duración media de los tracklets y reduciendo el porcentaje de fragmentos cortos. Su efecto sobre MOTA y HOTA fue necesariamente limitado, al no introducir nuevas detecciones.

Interpretación

El linking offline no sustituye al tracking online, sino que actúa como una segunda capa de coherencia temporal. Su principal valor aparece cuando el tracker ya genera trayectorias razonables, pero todavía deja cortes, gaps o reasignaciones localizadas.

Limitaciones

El método no recupera falsos negativos del detector ni corrige errores severos de localización frame a frame. Además, si se vuelve demasiado agresivo, puede introducir fusiones incorrectas entre jugadores distintos.

Conclusión parcial

El tracklet linking offline constituye una herramienta complementaria y modular para mejorar la continuidad de identidad, especialmente útil cuando el tracker online produce trayectorias parcialmente correctas pero todavía fragmentadas.

10.1. Motivación del tracklet linking

Tras el análisis del bloque online, quedó claro que parte del problema de identidad no se resolvía únicamente ajustando pesos dentro del tracker. Incluso en configuraciones competitivas seguían apareciendo fragmentación, gaps internos y errores de continuidad espacial. Esta observación llevó a plantear un cambio de perspectiva: en lugar de decidir todo exclusivamente frame a frame, podía resultar más útil analizar las trayectorias ya formadas y corregirlas a posteriori.

El enfoque offline parte de una idea sencilla. Si el tracker genera varios fragmentos que en realidad pertenecen al mismo jugador, esos fragmentos pueden compararse como unidades temporales completas: cuándo terminan y empiezan, cuánta distancia espacial los separa, cuánto duran y, si se desea, qué apariencia media presentan. De este modo, la unidad de decisión deja de ser la detección instantánea y pasa a ser el *tracklet*.

Este cambio de perspectiva aporta además una ventaja metodológica importante. El linking offline no requiere modificar el núcleo del tracker ni volver a ejecutar detección y asociación desde cero. Se aplica sobre salidas MOT ya generadas, lo que lo convierte en un procedimiento modular, reproducible y fácil de analizar de forma aislada. Por ello, el objetivo de este capítulo no es competir con el tracker online en todos los aspectos, sino estudiar si una segunda capa de coherencia temporal puede corregir parte de la fragmentación residual.

10.2. Construcción y análisis de tracklets

El primer paso del pipeline consiste en construir los tracklets a partir de la salida del tracker. Cada tracklet se define como una secuencia temporal continua de detecciones asociadas a un mismo ID, con un frame inicial, un frame final, una duración total y una colección de observaciones intermedias. A partir de estos elementos, se calculan estadísticas útiles para el linking posterior.

Entre las magnitudes analizadas destacan la duración del tracklet, su frame de inicio

y fin, la posición de la primera y última caja, los gaps temporales entre tracklets candidatos y la distancia espacial entre el final de uno y el inicio de otro. Cuando la variante utiliza información visual, también se calcula un embedding representativo de la cola del tracklet emisor y de la cabeza del tracklet receptor.

Este análisis exploratorio es importante porque permite fijar umbrales razonables para el linking. En vez de elegir valores arbitrarios de distancia máxima o gap máximo, se observan primero las distribuciones reales del clip: cuánto suelen durar los tracklets, qué gaps aparecen con frecuencia y qué distancias espaciales son plausibles en una reconexión legítima. De este modo, el diseño del postprocesado queda guiado por la estructura real de los datos y no solo por intuición.

Tabla 10: Resumen del análisis exploratorio previo sobre la salida base del tracker.

Magnitud	Valor
Tracklets totales	62
Detecciones totales	11 415
Frames del clip	750
Duración media de tracklet	190.2 f
Duración mediana de tracklet	100.0 f
Percentil 75 de duración	402 f
Gap mediano entre candidatos	65.5 f
Percentil 75 de gap	116 f
Distancia espacial mediana	483.2 px

10.3. Linking geométrico y criterios de fusión

Una vez contruidos los tracklets, el siguiente paso consiste en generar candidatos de fusión. Dos tracklets solo pueden aspirar a enlazarse si cumplen ciertas condiciones mínimas: cercanía temporal, una distancia espacial compatible y, en las variantes que lo incorporan, una similitud visual suficiente. Sobre esos candidatos se define un score compuesto que combina distintas fuentes de evidencia.

La primera componente es temporal: cuanto menor es el gap entre el final del tracklet A y el inicio del tracklet B , mayor plausibilidad existe de que ambos pertenezcan a una misma trayectoria. La segunda componente es espacial: cuanto menor es la distancia entre la última posición de A y la primera de B , más coherente resulta la fusión. La tercera componente, cuando se activa, es visual: la similitud coseno entre embeddings medios de cola y cabeza introduce una señal adicional de compatibilidad de apariencia.

De forma general, el score final puede expresarse como

$$\text{score}_{final} = w_T \cdot \text{score}_{temporal} + w_S \cdot \text{score}_{espacial} + w_V \cdot \text{score}_{visual},$$

donde las puntuaciones temporal y espacial se normalizan respecto a umbrales máximos de gap y distancia. A partir de estos scores, el pipeline resuelve los enlaces mediante una estrategia greedy, priorizando los candidatos mejor puntuados y evitando asignaciones incompatibles entre sí.

Desde el punto de vista conceptual, el linking geométrico representa la forma más conservadora del método: solo enlaza cuando la continuidad temporal y espacial es muy plausible. La introducción del término visual permite flexibilizar el método para candidatos más ambiguos, pero también aumenta el riesgo de fusiones erróneas si la señal de apariencia se sobrevalora. Por ello, el bloque experimental de este capítulo no debe leerse como una búsqueda ciega del mayor número de fusiones posible, sino como un estudio del equilibrio entre agresividad de enlace y coherencia final de identidad.

10.4. Experimentos principales sobre v0

El grueso de la evaluación offline se llevó a cabo inicialmente sobre la salida **v0** de ByteTrack, es decir, la versión sin ReID online. Esta elección tenía sentido por dos motivos. En primer lugar, **v0** proporciona una línea base limpia, donde la fragmentación no está ya alterada por decisiones de apariencia internas al tracker. En segundo lugar, permite comprobar hasta qué punto un postprocesado offline puede recuperar continuidad de identidad sin depender de un módulo ReID activado desde el origen.

A partir de **v0** se evaluaron varias variantes de linking con diferente agresividad. Las configuraciones más conservadoras usaban umbrales reducidos de gap temporal y distancia espacial, buscando fusiones muy seguras. Las configuraciones más agresivas ampliaban estos umbrales y, en algunos casos, incorporaban embeddings visuales para decidir entre candidatos más lejanos. Esta progresión experimental permitió identificar el compromiso entre seguridad de enlace y capacidad real de compactar trayectorias.

Tabla 11: Resumen de variantes offline evaluadas sobre la salida v0.

Experimento	IDs	Dur. media	Short %	Fusiones	max-gap	max-dist
v0 baseline	62	190.2	14.5 %	0	–	–
EXP-3 conservador sin ReID	50	237.1	10.0 %	10	30	200
EXP-4 agresivo sin ReID	38	318.5	2.6 %	24	115	400
EXP-5 conservador th alto	53	224.1	7.5 %	9	80	300
EXP-6 con ReID conservador	48	248.6	4.2 %	14	80	300
EXP-7 con ReID agresivo	45	268.2	2.2 %	17	115	600

Los resultados muestran una mejora consistente en las métricas más sensibles al linking: disminución del número total de IDs, reducción de *ID switches* por minuto, incremento de la duración media de tracklets y reducción del porcentaje de fragmentos cortos. En cambio, el efecto sobre MOTA y HOTA fue mucho más contenido, algo esperable dado que el postprocesado no añade nuevas detecciones.

Dentro de este bloque, la variante más interesante fue **EXP-7**. Esta configuración reduce los IDs de 62 a 45, alarga la duración media de tracklets de 190 a 268 frames y baja el porcentaje de tracklets cortos de 14.5 % a 2.2 %. Además, reduce de forma apreciable la tasa de cambios de identidad por minuto. El resultado más importante aquí no es tanto una supuesta mejora espectacular en métricas globales, sino la evidencia de que un linking offline bien calibrado puede actuar como mecanismo real de compactación de identidad sobre una baseline sin ReID.

Tabla 12: Comparación entre v0, EXP-7 y una referencia online compacta.

Configuración	HOTA	MOTA	IDF1	IDSW	Frag	IDs
v0 baseline	60.0 %	80.7 %	75.6 %	45	119	62
EXP-7 offline	59.2 %	80.8 %	74.2 %	35	118	45
v1 ReID online	59.3 %	79.4 %	75.6 %	36	133	30

10.5. Aplicación sobre v1

Una vez validado el método sobre v0, el siguiente paso natural fue estudiar su aplicación sobre una salida online más compacta, en particular v1. Esta transición es metodológicamente relevante porque cambia la naturaleza del problema. En v0, el linking corrige sobre todo fragmentación geométrica. En v1, en cambio, el sistema ya ha compactado muchas identidades, pero conserva errores espaciales y semánticos

más sutiles, como teletransportes o gaps mal resueltos.

Por ello, el linking sobre **v1** no debe entenderse como una simple repetición del experimento anterior, sino como una segunda fase con un objetivo distinto: ya no se trata solo de fusionar fragmentos cortos, sino de decidir cuándo conviene preservar la continuidad obtenida online y cuándo, por el contrario, es necesario cortar o impedir una reconexión incoherente.

El informe unificado muestra precisamente que el linking sobre **v1** debe leerse con cuidado. Aplicado sin preparación adicional, su efecto puede ser pequeño, porque **v1** ya llega muy compactado desde el tracker online. Sin embargo, cuando se combina con estrategias que abren el espacio de linking mediante división o saneamiento previo de trayectorias, el postprocesado vuelve a tener margen de actuación real. Esto confirma que online y offline no compiten exactamente por lo mismo: el online previene fragmentación desde el origen, mientras que el offline corrige fragmentación residual o incoherencias que sobreviven al proceso frame a frame.

10.6. Generalización a múltiples secuencias

Una cuestión importante era determinar si el linking offline estaba sobreajustado a una única secuencia o si, por el contrario, podía generalizar a otros clips del mismo dominio. Para responder a esta pregunta se aplicó el pipeline geométrico a múltiples secuencias adicionales de SoccerNet. El objetivo de esta fase no era optimizar finamente cada vídeo, sino comprobar si la reducción de fragmentación e ID switches aparecía también fuera del clip de desarrollo.

Los resultados mostraron una mejora consistente en varias secuencias, especialmente en términos de reducción de *ID switches*. La disminución relativa osciló entre aproximadamente el -11% y el -22% , con una mejora media cercana al -18% . Además, el número total de IDs también se redujo de manera sistemática. Esta tendencia es importante porque sugiere que el pipeline offline no está sobreajustado a un único vídeo, sino que captura una estructura de error relativamente estable dentro del dominio SoccerNet.

Tabla 13: Generalización del linking geométrico offline a cinco secuencias de Soccer-Net.

Secuencia	IDSW baseline	IDSW linked	Δ IDSW
SNMOT-060	45	35	-22 %
SNMOT-105	41	32	-22 %
SNMOT-167	46	41	-11 %
SNMOT-074	27	22	-19 %
SNMOT-111	19	16	-16 %

Desde el punto de vista del TFG, esta generalización refuerza una idea metodológica fuerte: un pipeline modular de tracking no solo permite comparar trackers distintos, sino también incorporar una segunda capa de corrección que mantiene su utilidad en varias secuencias sin necesidad de rediseñar por completo el sistema.

10.7. Discusión: online frente a offline

El resultado más importante de este capítulo es que el linking offline no sustituye al tracking online, sino que lo complementa. Ambos niveles resuelven problemas distintos. El online decide de forma inmediata y local entre detecciones frame a frame, mientras que el offline dispone de una perspectiva temporal más amplia y puede revisar trayectorias ya formadas, detectando fragmentación, cortes o incoherencias que el proceso online no consigue resolver bien.

Esto explica por qué no debe juzgarse el linking principalmente por métricas como MOTA o HOTA. Al no introducir nuevas detecciones, su capacidad de alterar la calidad global de detección es limitada. Su aportación real aparece en métricas de identidad y estructura de trayectoria: número total de IDs, duración media de tracklets, porcentaje de fragmentos cortos e *ID switches* por minuto.

En consecuencia, el aprendizaje principal de este bloque no es solo que una variante concreta haya funcionado mejor que otra, sino que el postprocesado offline constituye una estrategia válida, interpretable y modular para mejorar la coherencia de identidad. Esta conclusión abre el camino al siguiente capítulo, donde el linking dejará de aplicarse únicamente sobre la línea base *v0* y pasará a estudiarse en combinación con modelos ReID más específicos de dominio.

11. Adaptación del ReID al dominio

Estructura del análisis

Objetivo del experimento

Evaluar si el entrenamiento específico de dominio mejora el comportamiento del módulo ReID respecto al modelo genérico SportsMOT, distinguiendo entre fútbol profesional y fútbol amateur, y analizar si el *tracklet linking* sigue aportando valor sobre estos modelos ya adaptados.

Material usado

Informe de evaluación final de modelos ReID específicos de dominio frente a SportsMOT, curvas de aprendizaje completas con `eval-freq=1`, y evaluación de *tracklet linking* geométrico sobre los mejores checkpoints profesional y amateur.

Configuración

Arquitectura OSNet x1.0 con preentrenamiento en ImageNet. Modelos evaluados: SportsMOT genérico, modelo específico profesional y modelo específico amateur. Todas las pruebas de tracking se realizaron con una misma configuración de ByteTrack, de manera que las diferencias observadas pudieran atribuirse principalmente al modelo ReID.

Resultados principales

El modelo específico profesional mejora ligeramente las métricas globales y la consistencia de identidad frente a SportsMOT, aunque incrementa el número total de IDs. En amateur, el modelo específico mejora claramente IDF1 y reduce los ID switches absolutos, pero no mejora MOTA y genera una sobreidentificación severa, aumentando de forma muy notable el número total de IDs. El linking aplicado sobre estos modelos tiene un efecto limitado y reduce sobre todo el número total de IDs.

Interpretación

La adaptación de dominio sí aporta información útil, pero su efecto no es uniforme. En profesional, el modelo específico resulta competitivo y mejora varias métricas clave. En amateur, la mejora en asociación fina viene acompañada de una fragmentación excesiva. Por ello, el valor del entrenamiento específico

no debe juzgarse solo por MOTA o IDF1, sino también por estabilidad e identidades totales.

Limitaciones

Los dos dominios presentan dificultades distintas y no admiten una lectura idéntica de resultados. Además, incluso los mejores modelos específicos pueden seguir necesitando postprocesado posterior para corregir sobreidentificación o fragmentación residual.

Conclusión parcial

El entrenamiento específico de dominio mejora la calidad del embedding y puede traducirse en mejores métricas de tracking, pero no garantiza automáticamente una mejor coherencia de identidad final. La conveniencia de usar un modelo específico depende del dominio y de qué métricas se prioricen.

11.1. Modelo baseline SportsMOT

El punto de partida de este bloque experimental fue el modelo ReID genérico entrenado en SportsMOT. Este baseline resulta especialmente útil porque no está especializado en un único dominio futbolístico, sino que proporciona una representación visual aprendida sobre un conjunto más amplio de escenarios deportivos. Desde el punto de vista metodológico, esto lo convierte en una referencia razonable para medir hasta qué punto el *fine-tuning* específico aporta valor real.

El uso de SportsMOT como baseline tenía además una ventaja importante: permitía comparar el efecto del entrenamiento específico sin modificar el resto del pipeline. En todas las pruebas de este capítulo, la configuración de tracking se mantuvo fija, de modo que las diferencias en métricas pudieran atribuirse al cambio de modelo ReID y no a variaciones de asociación, memoria o umbrales del tracker.

Por tanto, SportsMOT no debe entenderse aquí como un modelo “débil”, sino como un baseline competitivo y bien calibrado frente al que se contrasta la utilidad del entrenamiento específico de dominio.

11.2. Curvas de aprendizaje y selección de checkpoints

Los modelos específicos se entrenaron con OSNet x1.0 siguiendo un protocolo estándar de *person re-identification*, con evaluación de validación en cada época. Esta

decisión fue importante porque permitió disponer de curvas de aprendizaje completas y seleccionar checkpoints a partir de evidencia empírica densa, en lugar de depender de una evaluación esporádica o de una elección manual aproximada.

El criterio de selección fue el máximo mAP de validación. En el caso profesional, el mAP alcanza el 100 % y el primer punto donde se observa esa convergencia completa corresponde al **Epoch 40**, por lo que ese checkpoint se selecciona como referencia final. En el caso amateur, la convergencia es más lenta y menos saturada; el mejor punto de validación se alcanza en **Epoch 98**, con un mAP inferior al del dominio profesional pero suficiente para justificar su elección como mejor checkpoint del entrenamiento.

Este procedimiento refuerza la solidez metodológica del capítulo. No se comparan modelos escogidos de manera arbitraria, sino checkpoints seleccionados con un criterio homogéneo y explícito. Además, las curvas permiten visualizar una diferencia interesante entre dominios: el profesional converge de forma más limpia y temprana, mientras que el amateur presenta una evolución más irregular, coherente con la mayor heterogeneidad del dominio.




Figura 20: Curvas de aprendizaje completas obtenidas con evaluación por época. La selección de checkpoints se basó en el máximo mAP de validación.

Tabla 14: Resumen del protocolo de entrenamiento y selección de checkpoints.

Aspecto	SportsMOT	Profesional	Amateur
Arquitectura	OSNet x1.0	OSNet x1.0	OSNet x1.0
Preentrenamiento	ImageNet + Sports-MOT	ImageNet + fine-tuning	ImageNet + fine-tuning
Dominio	Multi-deporte	Fútbol profesional	Fútbol amateur
Checkpoint usado	baseline disponible	Epoch 40	Epoch 98
Criterio de selección	referencia base	primer mAP máximo	máximo mAP
Evaluación	protocolo fijo	eval-freq = 1	eval-freq = 1

11.3. Entrenamiento específico en fútbol profesional

En el dominio profesional, el modelo específico muestra una mejora ligera pero consistente frente a SportsMOT en varias métricas de interés. La mejora no es espectacular en términos absolutos, pero sí suficientemente estable como para considerarla real: aumenta ligeramente MOTA, mejora IDF1 y reduce el número de *ID switches*. Esta combinación es especialmente valiosa porque no se limita a mejorar cobertura global, sino que también sugiere una mejor discriminación de identidad.

Sin embargo, la lectura del resultado no debe ser simplista. El modelo profesional específico mejora algunas métricas centrales del tracking, pero lo hace a costa de incrementar el número total de IDs y el número de fragmentaciones. Esto indica que el embedding específico es más sensible y, en algunos casos, más discriminativo, pero también puede romper más trayectorias cuando la señal no es suficientemente estable. En otras palabras, gana en precisión fina de identidad, pero no necesariamente en compactación estructural del conjunto de trayectorias.

Esta tensión es muy importante para la memoria porque muestra que el entrenamiento específico no produce una mejora unidimensional. En profesional, la conclusión correcta no es “el modelo específico gana en todo”, sino algo más matizado: mejora varias métricas clave y resulta competitivo frente al baseline genérico, aunque introduce más IDs de los deseables si se prioriza una lectura muy conservadora de continuidad.

Tabla 15: Comparación entre SportsMOT y el modelo específico profesional.

Modelo	HOTA	MOTA	IDF1	IDSW	IDSW/min	Frag.	IDs	Prec.	Rec.
SportsMOT (Baseline v1)	—	81.95 %	77.14 %	32	63.9	91	30	98.26 %	83.67 %
SNMOT-060 Epoch 40	60.2 %	81.99 %	78.11 %	30	60.0	101	41	98.31 %	83.65 %

11.4. Entrenamiento específico en fútbol amateur

El comportamiento del modelo específico amateur es más complejo y, en cierto sentido, más revelador. Aquí el entrenamiento específico mejora sobre todo la calidad de asociación medida por IDF1 y reduce los ID switches absolutos respecto a SportsMOT, además de aumentar ligeramente el *recall*. Sin embargo, no mejora MOTA y tampoco mejora la precisión, por lo que el balance global debe interpretarse con cautela.

Sin embargo, esa lectura sería incompleta si se atendiera solo a métricas agregadas de asociación. Aunque el modelo específico reduce los ID switches absolutos respecto a SportsMOT, incrementa de forma muy notable el número total de IDs generados. En la práctica, esto significa que el sistema se vuelve más sensible y consigue seguir mejor el contenido global de la escena, pero lo hace fragmentando en exceso las identidades. El informe interpreta este comportamiento como un caso de sobreidentificación severa, ya que el número de IDs sube de 28 a 42 en un vídeo con aproximadamente 21 jugadores reales.

Tabla 16: Comparación entre SportsMOT y el modelo específico amateur.

Modelo	HOTA	MOTA	IDF1	IDSW	IDSW/min	Frag.	IDs	Prec.	Rec.
SportsMOT (Baseline v1)	–	44.81 %	39.72 %	91	86.4	141	28	66.78 %	90.14 %
Amateur Epoch 98	36.8 %	44.72 %	43.78 %	80	76.0	138	42	66.69 %	90.21 %

Esta tabla deja ver con claridad la naturaleza del trade-off. El modelo específico amateur mejora IDF1 y reduce los ID switches absolutos, pero no mejora MOTA y eleva de forma muy marcada el número total de trayectorias. Por tanto, no puede hablarse de una victoria limpia como en el dominio profesional, sino de una mejora parcial con costes estructurales importantes.

Tabla 17: Resumen del trade-off del modelo específico amateur frente a SportsMOT.

Magnitud	Cambio del modelo amateur específico
MOTA	-0.09 pp
IDF1	+4.06 pp
Precision	-0.09 pp
Recall	+0.07 pp
ID switches	-11 abs. / menor IDSW bruto
Total IDs	+50 %
Interpretación	Mejor asociación fina, peor compactación de identidad

11.5. Comparación entre modelos genéricos y específicos

A la luz de ambos dominios, la comparación entre SportsMOT y modelos específicos no puede resolverse con una única regla universal. En fútbol profesional, el modelo específico es competitivo y mejora varias métricas importantes, aunque incrementa el número total de IDs. En fútbol amateur, la mejora en asociación fina viene acompañada de un deterioro mucho más acusado en compactación de identidad y sobreidentificación.

Esta diferencia obliga a interpretar los resultados en función del objetivo real del sistema. Si se prioriza maximizar MOTA, IDF1 y algunas métricas de asociación fina, el entrenamiento específico resulta atractivo, especialmente en profesional. Si se prioriza contener el número de identidades generadas y mantener trayectorias más compactas, entonces el juicio es más matizado, y SportsMOT sigue siendo una referencia muy sólida.

Desde el punto de vista del TFG, esta comparación deja una conclusión metodológica fuerte: la adaptación de dominio no debe juzgarse solo por mAP de validación o por mejoras puntuales en tracking global, sino por su impacto completo sobre la coherencia de identidad. Precisamente por eso este capítulo no cierra todavía la elección del sistema final, sino que prepara el terreno para una comparación global posterior entre modelos, integración online y linking offline.

Tabla 18: Síntesis comparativa entre baseline genérico y modelos específicos.

Dominio	Ventaja del modelo específico	Coste principal
Profesional	Mejora ligera en MOTA, IDF1 e IDSW	Aumento de IDs y fragmentaciones
Amateur	Mejor asociación fina (IDF1) y menor IDSW absoluto	Sobreidentificación severa y sin mejora real en MOTA

11.6. Aplicación de tracklet linking sobre los mejores modelos

Una vez seleccionados los mejores checkpoints específicos, se aplicó sobre ellos el *tracklet linking* geométrico para comprobar si el postprocesado offline seguía teniendo margen de mejora. El resultado general es que el linking tiene un impacto limitado sobre modelos que ya incorporan un ReID online relativamente fuerte. En ambos dominios, la mejora más clara se observa en el número total de IDs, que disminuye en 4 unidades, mientras que el resto de métricas cambia muy poco o incluso empeora ligeramente.

En profesional, el baseline con el mejor modelo específico presenta 30 ID switches y 41 IDs. Tras aplicar linking, los ID switches suben ligeramente a 31, mientras que los IDs bajan a 37. MOTA cae de forma casi despreciable e IDF1 permanece estable. En amateur, la situación es parecida: el linking reduce el número total de IDs, pero no consigue reducir los ID switches y tampoco mejora las métricas globales. Esto sugiere que el linking actúa aquí como una capa de refinamiento moderado, no como una corrección transformadora del sistema.

La lectura correcta de estos resultados es que el linking sobre modelos ya fuertes no funciona como una segunda revolución del pipeline, sino como un ajuste final. En profesional, ayuda a contener algo la sobrefragmentación residual del modelo específico. En amateur, mitiga levemente la sobreidentificación, pero no resuelve el problema estructural de fondo. Esto encaja bien con la lógica general del TFG: el linking offline es complementario al ReID online, no un reemplazo mágico de sus limitaciones.

Tabla 19: Impacto del linking geométrico sobre los mejores modelos específicos.

Dominio	Condición	MOTA	IDF1	IDSW	IDs
Profesional	Baseline específico	81.99 %	78.11 %	30	41
Profesional	Específico + linking	81.96 %	78.11 %	31	37
Amateur	Baseline específico	44.72 %	43.78 %	80	42
Amateur	Específico + linking	44.62 %	43.76 %	80	38

12. Curación manual de resultados y herramienta de apoyo

12.1. Necesidad de corrección manual en salidas MOT

12.2. Script `annotate_review.py`

12.3. Script `annotate_review_precise.py`

12.4. Aplicación web Gradio del pipeline completo

12.5. Utilidad práctica dentro del flujo experimental

12.6. Limitaciones actuales de la herramienta

13. Resultados globales y selección del sistema final

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

13.1. Megatabla de configuraciones

13.2. Comparación global de enfoques

13.3. Criterios de selección del sistema final

13.4. Pipeline final elegido y justificación

13.5. Discusión sobre trade-offs

14. Conclusiones

14.1. Respuesta a los objetivos del anteproyecto

14.2. Principales hallazgos

14.3. Aportaciones del trabajo

14.4. Limitaciones

14.5. Trabajo futuro

Referencias

- [1] Gioele Ciaparrone et al. «Deep Learning in Video Multi-Object Tracking: A Survey». En: *Neurocomputing* (2020).
- [2] Anthony Cioppa et al. «SoccerNet-Tracking: Multiple Object Tracking Dataset and Benchmark in Soccer Videos». En: *arXiv preprint arXiv:2204.06918* (2022).
- [3] Yutao Cui et al. «SportsMOT: A Large Multi-Object Tracking Dataset in Multiple Sports Scenes». En: *arXiv preprint arXiv:2304.05170* (2023).
- [4] Ruopeng Gao, Yijun Zhang y Limin Wang. «Multiple Object Tracking as ID Prediction». En: *arXiv preprint arXiv:2403.16848* (2024).
- [5] Jonathon Luiten et al. «HOTA: A Higher Order Metric for Evaluating Multi-Object Tracking». En: *arXiv preprint arXiv:2009.07736* (2020).
- [6] Nicolai Wojke, Alex Bewley y Dietrich Paulus. «Simple Online and Realtime Tracking with a Deep Association Metric». En: *arXiv preprint arXiv:1703.07402* (2017).
- [7] Yifu Zhang et al. «ByteTrack: Multi-Object Tracking by Associating Every Detection Box». En: *arXiv preprint arXiv:2110.06864* (2021).



UNIVERSIDAD
DE MÁLAGA

| **uma.es**

E.T.S. DE INGENIERÍA INFORMÁTICA

E.T.S de Ingeniería Informática
Bulevar Louis Pasteur, 35
Campus de Teatinos
29071 Málaga