



UNIVERSIDAD DE MÁLAGA



Trabajo fin de grado

Sistema de tracking y reidentificación de jugadores en fútbol amateur

Realizado por
Soriano Muñoz Juan Ignacio

Profesor encargado:
Luque Baena Rafael Marcos
Jerez Aragonés Jose Manuel
Departamento
Lenguajes y Ciencias de la Computación

MÁLAGA, DICIEMBRE de 2024



UNIVERSIDAD
DE MÁLAGA



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA
ESTUDIANTES DE INGENIERÍA BIOINFORMÁTICA

Sistema de tracking y reidentificación de jugadores en fútbol amateur

Trabajo fin de grado

Realizado por
Soriano Muñoz Juan Ignacio

Profesor encargado:
Luque Baena Rafael Marcos
Jerez Aragonés Jose Manuel

Departamento
Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA
MÁLAGA, DICIEMBRE DE 2024

Índice

1. Introducción	6
1.1. Contexto del problema	6
1.2. Motivación	6
1.3. Objetivos del TFG	7
1.4. Alcance y limitaciones	8
1.5. Estructura de la memoria	8
2. Estado del arte	9
2.1. Multi-Object Tracking	9
2.2. Re-Identification	9
2.3. Paradigmas de seguimiento: <i>tracking-by-detection</i> frente a métodos <i>end-to-end</i>	10
2.4. Seguimiento de jugadores en deporte y fútbol	11
2.5. Métricas de evaluación	12
3. Planteamiento del problema	14
3.1. Dificultades específicas del dominio amateur	14
3.2. Oclusiones, cruces, paneos y salidas de escena	14
3.3. Coherencia de identidad y coherencia geométrica	15
3.4. Preguntas de investigación	16
3.5. Hipótesis de trabajo	17
4. Datos, materiales y entorno experimental	18
4.1. Datasets utilizados	18
4.2. Secuencias profesionales y amateur	18
4.3. Ground truth y pseudo-ground-truth	18
4.4. Entorno tecnológico	18
4.5. Organización reproducible de experimentos	18

5. Metodología general	19
5.1. Diseño iterativo del trabajo	19
5.2. Flujo general del pipeline	19
5.3. Protocolo de evaluación cuantitativa	20
5.4. Protocolo de evaluación cualitativa	21
5.5. Jerarquía de resultados: definitivos frente a exploratorios	22
6. Comparativa inicial de trackers	24
6.1. Selección de trackers candidatos	25
6.2. ByteTrack	25
6.3. DeepEIoU	26
6.4. MOTIP	27
6.5. Resultados iniciales y selección del tracker base	27
7. Diagnóstico del problema de identidad	29
7.1. Análisis visual de fallos en ByteTrack	29
7.2. Casos críticos: oclusiones, jugador caído y teletransportación	29
7.3. Influencia del <code>track_buffer</code>	29
7.4. Heurísticas tempranas y sus limitaciones	29
7.5. Conclusión del diagnóstico	29
8. Análisis del módulo ReID	30
8.1. Modelo OSNet y embeddings	30
8.2. Verificación inicial del extractor ReID	30
8.3. Análisis experimental de embeddings	30
8.4. Separabilidad por identidad y por equipo	30
8.5. Discusión: problema del embedding frente a problema de integración	30
9. Integración online de ReID en ByteTrack	31
9.1. Configuración base v1	31
9.2. Recalibración de la fusión IoU–ReID	31

9.3. Experimentos v0, v1, v2 y v3	31
9.4. Evaluación cualitativa de v1	31
9.5. Trade-offs del enfoque online	31
10.Postprocesado offline mediante tracklet linking	32
10.1. Motivación del tracklet linking	32
10.2. Construcción y análisis de tracklets	32
10.3. Linking geométrico y criterios de fusión	32
10.4. Experimentos principales sobre v0	32
10.5. Aplicación sobre v1	32
10.6. Generalización a múltiples secuencias	32
10.7. Discusión: online frente a offline	32
11.Adaptación del ReID al dominio	33
11.1. Modelo baseline SportsMOT	33
11.2. Entrenamiento específico en fútbol profesional	33
11.3. Entrenamiento específico en fútbol amateur	33
11.4. Curvas de aprendizaje y selección de checkpoints	33
11.5. Comparación entre modelos genéricos y específicos	33
11.6. Aplicación de tracklet linking sobre los mejores modelos	33
12.Curación manual de resultados y herramienta de apoyo	34
12.1. Necesidad de corrección manual en salidas MOT	34
12.2. Script <code>annotate_review.py</code>	34
12.3. Script <code>annotate_review_precise.py</code>	34
12.4. Aplicación web Gradio del pipeline completo	34
12.5. Utilidad práctica dentro del flujo experimental	34
12.6. Limitaciones actuales de la herramienta	34
13.Resultados globales y selección del sistema final	35
13.1. Megatabla de configuraciones	35

13.2. Comparación global de enfoques	35
13.3. Criterios de selección del sistema final	35
13.4. Pipeline final elegido y justificación	35
13.5. Discusión sobre trade-offs	35
14. Conclusiones	36
14.1. Respuesta a los objetivos del anteproyecto	36
14.2. Principales hallazgos	36
14.3. Aportaciones del trabajo	36
14.4. Limitaciones	36
14.5. Trabajo futuro	36

1. Introducción

1.1. Contexto del problema

El seguimiento multiobjeto (*Multi-Object Tracking*, MOT) es una tarea central de la visión por computador que persigue estimar la trayectoria y mantener la identidad de múltiples objetos a lo largo del tiempo en una secuencia de vídeo. En los sistemas modernos, el paradigma dominante es *tracking-by-detection*, en el que primero se detectan los objetos en cada fotograma y, posteriormente, se resuelve su asociación temporal mediante pistas geométricas, dinámicas y de apariencia [1, 6, 7].

En el ámbito deportivo, y particularmente en fútbol, este problema adquiere una relevancia práctica inmediata. Un sistema de tracking robusto permite estimar posiciones, trayectorias, ocupación espacial, distancias recorridas y patrones colectivos, información que resulta útil tanto para analítica táctica como para generación automática de estadísticas. Sin embargo, los vídeos de retransmisión plantean dificultades específicas: fuertes cambios de cámara, oclusiones frecuentes, cruces entre jugadores, escalas variables, similitud visual entre futbolistas del mismo equipo y desapariciones temporales al salir del campo visual [2, 3].

La disponibilidad de benchmarks específicos ha permitido estudiar este problema de forma más sistemática. SoccerNet-Tracking formaliza el seguimiento de jugadores, árbitros y balón en vídeo de fútbol, y muestra que el problema está lejos de resolverse en escenarios con movimiento rápido y oclusión severa [2]. Por su parte, SportsMOT amplía el análisis a varios deportes y concluye que, en escenas deportivas, una parte sustancial de la dificultad reside en la asociación de identidades, no solo en la detección [3].

1.2. Motivación

Este trabajo nace de una necesidad doble. Por un lado, existe interés en disponer de un pipeline de seguimiento aplicable a fútbol amateur, donde habitualmente no se cuenta con sistemas comerciales de captura, sensores invasivos ni recursos de anotación abundantes. Por otro, aunque trackers generales como ByteTrack ofrecen muy buen rendimiento en benchmarks estándar, su comportamiento en fútbol no es directamente óptimo, especialmente cuando la calidad de la señal visual, las oclusiones y la reentrada de jugadores en escena degradan la consistencia de identidad [7, 2].

A ello se suma el hecho de que los métodos basados en apariencia, normalmente implementados mediante módulos de *person re-identification* (ReID), pueden ayu-

dar a reducir cambios de identidad al complementar la asociación geométrica. Deep SORT mostró tempranamente que incorporar una métrica profunda de apariencia podía reducir los *identity switches* al atravesar oclusiones más largas [6]. Sin embargo, en entornos deportivos la apariencia también resulta ambigua: jugadores del mismo equipo comparten colores, la resolución de los dorsales no siempre es suficiente y los cambios de pose o escala pueden deteriorar la utilidad del embedding visual [3, 2].

La motivación concreta del TFG consiste, por tanto, en estudiar de forma experimental hasta qué punto un pipeline basado en ByteTrack puede adaptarse al dominio del fútbol mediante tres vías complementarias: la integración online de ReID, el postprocesado offline mediante *tracklet linking* y el ajuste de modelos de ReID al dominio específico. Además, se persigue que el resultado no sea solo un análisis teórico, sino también una herramienta utilizable para ejecutar experimentos, visualizar resultados y evaluar secuencias con y sin *ground truth*.

1.3. Objetivos del TFG

El objetivo general de este trabajo es diseñar, analizar y evaluar un pipeline de seguimiento multiobjeto aplicado a fútbol, con especial atención a la continuidad de identidad en escenarios profesionales y amateur.

De este objetivo general se derivan los siguientes objetivos específicos:

- Comparar distintos enfoques de tracking multiobjeto y seleccionar una base de trabajo adecuada para el dominio del fútbol.
- Analizar el comportamiento del módulo de re-identificación, tanto de forma aislada como integrado en el tracker, para entender qué información codifica y cuáles son sus limitaciones.
- Estudiar distintas estrategias de integración online de ReID dentro de ByteTrack, evaluando sus ventajas y sus posibles degradaciones.
- Diseñar y validar un postprocesado offline basado en *tracklet linking* para reducir fragmentación e incoherencias geométricas.
- Investigar el impacto del dominio mediante el uso de un modelo genérico de ReID y modelos específicos entrenados para fútbol profesional y amateur.
- Construir una herramienta de apoyo que permita ejecutar el pipeline completo, visualizar resultados y facilitar la evaluación experimental.

1.4. Alcance y limitaciones

El trabajo se centra en seguimiento multiobjeto con una única cámara de vídeo, utilizando secuencias de fútbol profesional y amateur. El núcleo experimental se apoya en ByteTrack como tracker base, modelos OSNet para ReID y un módulo de *tracklet linking* como postprocesado offline. La evaluación se realiza principalmente mediante métricas estándar de MOT, como MOTA, IDF1, HOTA, *ID switches*, fragmentación y número total de identidades, complementadas con análisis cualitativo cuando las métricas por sí solas no capturan errores geoméricamente incoherentes [2, 7, 3].

No obstante, el trabajo presenta también varias limitaciones. En primer lugar, no se aborda un sistema end-to-end de reconstrucción global del estado del partido, sino un pipeline modular centrado en detección, asociación e identidad. En segundo lugar, la parte amateur exige una fase adicional de curación manual para construir un *pseudo-ground truth*, lo que limita la escalabilidad del proceso. Finalmente, aunque se estudian modelos específicos de dominio, el alcance del TFG no incluye un rediseño completo del tracker ni un entrenamiento conjunto detector-ReID-tracker.

1.5. Estructura de la memoria

La memoria se organiza del siguiente modo. En primer lugar, se presenta el estado del arte y el planteamiento del problema. A continuación, se describen los datos, materiales y la metodología general empleada. Después, se desarrolla la comparación inicial de trackers, el diagnóstico del problema de identidad y el análisis del módulo ReID. Sobre esa base, se estudian dos líneas principales de mejora: la integración online de ReID en ByteTrack y el postprocesado offline mediante *tracklet linking*. Posteriormente, se analiza la adaptación del ReID al dominio mediante modelos específicos y se describe la herramienta de apoyo desarrollada para la ejecución del pipeline y la curación manual de resultados. Finalmente, se integran los resultados globales, se justifica la selección del sistema final y se exponen las conclusiones y líneas de trabajo futuro.

2. Estado del arte

2.1. Multi-Object Tracking

El problema de *Multi-Object Tracking* (MOT) consiste en estimar la trayectoria de múltiples objetos a lo largo del tiempo manteniendo una identidad consistente para cada uno de ellos. En visión por computador, esta tarea suele abordarse sobre secuencias de vídeo monocámara y combina dos subproblemas fundamentales: la localización de los objetos en cada fotograma y su asociación temporal entre fotogramas consecutivos o distantes [1, 7].

Aunque buena parte de la literatura se ha desarrollado sobre escenarios peatonales y urbanos, el MOT sigue siendo un problema abierto cuando aparecen oclusiones prolongadas, interacciones densas, cambios bruscos de movimiento o degradación de la apariencia. En estos casos, el rendimiento del tracker depende no solo de la calidad del detector, sino también de la forma en que combina información geométrica, temporal y visual para preservar identidades consistentes [1, 5].

Desde un punto de vista metodológico, la evolución reciente del MOT puede entenderse a partir de dos grandes familias de enfoques: por un lado, los métodos modulares basados en detección, conocidos como *tracking-by-detection*; por otro, los métodos más integrados o *end-to-end*, entre los que destacan varias propuestas basadas en transformers y en predicción directa de identidad. Esta distinción es especialmente relevante para el presente TFG, ya que parte del trabajo consistió precisamente en comparar ambos paradigmas antes de centrar el desarrollo en un pipeline modular.

2.2. Re-Identification

La *Re-Identification* (ReID) es una técnica orientada a representar una identidad mediante un embedding de apariencia que permita comparar recortes de una misma persona u objeto a lo largo del tiempo. En un pipeline de tracking, su función es complementar la asociación geométrica con una señal visual capaz de sostener identidades incluso cuando la predicción dinámica resulta ambigua. En la práctica, un modelo ReID transforma cada recorte en un vector de características y la similitud entre esos vectores se utiliza como criterio adicional de asociación [6, 1].

La incorporación de embeddings profundos a la asociación temporal se popularizó con Deep SORT, que mostró que una métrica de apariencia aprendida podía reducir los cambios de identidad frente a métodos puramente geométricos [6]. Desde enton-

ces, muchos trackers han incorporado módulos ReID como parte central o auxiliar de su estrategia de asociación, especialmente en escenarios donde las oclusiones, los cruces y las desapariciones temporales son frecuentes.

Sin embargo, la utilidad de la ReID depende fuertemente del dominio. En escenas deportivas, y en particular en deportes de equipo, la apariencia entre instancias es simultáneamente parecida y potencialmente discriminativa: varios jugadores comparten colores y estructura visual global, pero pueden diferenciarse por dorsal, textura, pose o detalles locales. SportsMOT subraya que precisamente esta mezcla de movimiento rápido y apariencia redundante convierte la asociación de identidades en el reto dominante del tracking deportivo [3]. Por ello, la efectividad del ReID no depende únicamente de su arquitectura, sino también del dominio en que se entrena y de cómo se integra dentro del tracker.

2.3. Paradigmas de seguimiento: *tracking-by-detection* frente a métodos *end-to-end*

El paradigma más extendido en MOT durante los últimos años ha sido el *tracking-by-detection*. En este esquema, la detección y la asociación se resuelven en etapas separadas: primero se detectan los objetos en cada fotograma y después se enlazan temporalmente mediante información de movimiento, solapamiento espacial, heurísticas de asignación y, en muchos casos, embeddings de apariencia [1, 6, 7]. Este enfoque tiene como principal ventaja su modularidad: cada componente puede mejorarse o sustituirse sin necesidad de rediseñar por completo el sistema.

Deep SORT constituye un ejemplo representativo de esta familia. El método combina un filtro de Kalman para modelar el movimiento, una estrategia clásica de asignación y una métrica profunda de apariencia para reforzar la asociación [6]. Posteriormente, otros métodos mantuvieron esta filosofía modular, aunque introduciendo mejoras específicas en la política de asociación. ByteTrack, por ejemplo, demostró que una parte importante de la fragmentación proviene de descartar demasiado pronto detecciones de baja confianza. Su propuesta consiste en asociar prácticamente todas las cajas de detección, incluidas aquellas con score menor, recuperando así instancias verdaderas que otros trackers perderían [7]. Esta idea resulta especialmente interesante en escenas con oclusión, donde las detecciones válidas tienden a degradarse temporalmente.

Frente a este paradigma modular, en los últimos años han aparecido métodos más integrados o *end-to-end*, en los que la identidad deja de resolverse únicamente como una asignación posterior basada en heurísticas y se incorpora de forma más directa

al propio proceso de predicción. Dentro de esta familia se encuentran varias propuestas basadas en transformers, que aprovechan su capacidad para modelar relaciones globales y dependencias temporales entre múltiples objetos. Estos enfoques aspiran a aprender de forma conjunta qué trayectorias deben mantenerse y cómo propagar la identidad a lo largo del tiempo, reduciendo la dependencia de reglas diseñadas manualmente.

MOTIP ejemplifica bien esta línea de trabajo. En lugar de formular el problema exclusivamente como una asociación entre detecciones frame a frame, plantea el tracking como un problema de predicción de identidad a partir del contexto histórico de las trayectorias [4]. Conceptualmente, esto desplaza parte de la carga del sistema desde el diseño explícito de funciones de coste y reglas de matching hacia un mecanismo aprendido que intenta decidir directamente qué identidad corresponde a cada observación.

Ambos paradigmas presentan fortalezas y debilidades. Los métodos *tracking-by-detection* suelen ser más interpretables, modulares y fáciles de adaptar cuando se desea reemplazar detector, módulo ReID o postprocesado de manera independiente. Los métodos *end-to-end*, por el contrario, pueden capturar dependencias más complejas y reducir la necesidad de heurísticas manuales, pero a cambio suelen ser menos transparentes y más dependientes del dominio de entrenamiento y de la calidad del protocolo experimental [7, 4]. En el contexto del presente trabajo, esta diferencia resultó especialmente relevante: mientras los métodos modulares ofrecían una base clara sobre la que analizar y modificar componentes, los métodos más integrados servían como referencia valiosa de un paradigma alternativo, aunque menos sencillo de intervenir.

2.4. Seguimiento de jugadores en deporte y fútbol

El tracking en deporte comparte la estructura general del MOT, pero introduce dificultades específicas que lo convierten en un dominio especialmente exigente. SportsMOT muestra que los deportes combinan dos propiedades difíciles de resolver simultáneamente: movimiento rápido y variable, y apariencias muy parecidas entre instancias que, aun así, deben distinguirse correctamente [3]. En consecuencia, la asociación es particularmente frágil cuando depende solo de proximidad geométrica o de una apariencia poco discriminativa.

En fútbol, además, el problema tiene una dimensión contextual muy marcada. SoccerNet-Tracking fue propuesto para cubrir la falta de benchmarks específicos de tracking en vídeo futbolístico y puso de manifiesto que el seguimiento conjunto de jugadores, árbitros y balón está lejos de estar resuelto [2]. El benchmark des-

taca fenómenos como oclusión severa, movimiento rápido, densidad de jugadores y dificultad para mantener identidades en secuencias largas de retransmisión.

La importancia de este problema no es únicamente académica. El tracking robusto en fútbol permite automatizar la extracción de trayectorias, estimar carga física, reconstruir ocupación espacial y facilitar análisis táctico sin necesidad de sensores invasivos, algo especialmente valioso en contextos amateur o semiprofesionales [2, 3]. Sin embargo, precisamente en esos contextos la calidad del vídeo suele ser menor y la disponibilidad de anotaciones es más limitada, lo que amplía la distancia entre los resultados de benchmark y la aplicabilidad práctica de los sistemas.

Por ello, una parte relevante del estado del arte reciente en deporte no se limita a proponer trackers más precisos, sino que insiste en la necesidad de datasets y protocolos de evaluación ajustados al dominio. Tanto SoccerNet-Tracking como SportsMOT desempeñan en este TFG un papel central como referencias para contextualizar el problema y justificar las decisiones experimentales adoptadas.

2.5. Métricas de evaluación

La evaluación en MOT requiere medir simultáneamente calidad de detección y calidad de asociación. Tradicionalmente, una de las métricas más utilizadas ha sido MOTA, que resume errores de falsas detecciones, pérdidas y cambios de identidad en una sola magnitud agregada. Junto a ella, métricas como IDF1 ponen el foco en la consistencia de identidad, valorando hasta qué punto las trayectorias predichas corresponden correctamente con las trayectorias reales [5].

No obstante, la literatura reciente ha señalado que estas métricas clásicas no siempre reflejan de forma equilibrada todos los tipos de error relevantes en tracking. HOTA fue propuesta precisamente para afrontar esta limitación, buscando un balance explícito entre detección y asociación y ofreciendo además descomposiciones que permiten interpretar con mayor claridad si una mejora procede de mejores detecciones o de una asociación más consistente [5]. En la práctica, HOTA se ha consolidado como una métrica especialmente útil cuando interesa valorar el comportamiento global de un tracker más allá de una única magnitud agregada.

Junto a estas métricas generales, en aplicaciones concretas resulta habitual analizar también medidas más directamente interpretables, como el número de *ID switches*, las fragmentaciones o el número total de identidades generadas por el sistema. En escenarios deportivos, donde la continuidad por jugador resulta esencial para reconstruir trayectorias largas y extraer estadísticas fiables, estas cantidades pueden llegar a ser tan importantes como las métricas agregadas [2, 5].

En consecuencia, un protocolo de evaluación sólido en MOT no debería descansar sobre una única métrica. La práctica más razonable consiste en combinar métricas globales, métricas centradas en identidad y análisis cualitativo cuando el dominio lo exige. Esta idea será central en el presente trabajo, donde la comparación entre configuraciones no se decide únicamente por la mejora de una métrica aislada, sino por el equilibrio entre continuidad de identidad, reducción de fragmentación y plausibilidad geométrica.

3. Planteamiento del problema

3.1. Dificultades específicas del dominio amateur

El seguimiento multiobjeto en fútbol presenta una dificultad estructural superior a la de otros escenarios de MOT más controlados. A diferencia de entornos urbanos o secuencias peatonales convencionales, en fútbol se combinan movimientos rápidos, aceleraciones bruscas, cambios de dirección frecuentes, agrupamientos densos y una apariencia altamente redundante entre jugadores del mismo equipo. Tanto SoccerNet-Tracking como SportsMOT señalan precisamente que una parte sustancial de la complejidad en escenas deportivas no reside únicamente en detectar correctamente a los jugadores, sino en mantener su identidad de forma consistente a lo largo del tiempo [2, 3].

En el caso concreto del fútbol amateur, estas dificultades se agravan por factores adicionales relacionados con la adquisición del vídeo. Es habitual trabajar con una única cámara, encuadres menos estables, menor resolución efectiva sobre los jugadores, iluminación menos homogénea y ausencia de sistemas auxiliares de sensorización. Como consecuencia, las pistas visuales finas, como el dorsal o detalles locales de textura, tienden a degradarse con facilidad, y la señal disponible para re-identificación se vuelve menos fiable que en secuencias profesionales de mayor calidad. Este problema es especialmente relevante cuando el sistema debe distinguir entre jugadores del mismo equipo cuya apariencia global es muy similar [3, 6].

Desde el punto de vista experimental, el dominio amateur introduce además una limitación metodológica importante: la escasez de anotaciones listas para evaluación y entrenamiento. Mientras que benchmarks como SoccerNet-Tracking proporcionan secuencias anotadas y un protocolo de evaluación bien definido [2], en el contexto amateur es frecuente que el investigador tenga que construir o depurar manualmente un *pseudo-ground truth* para poder calcular métricas consistentes y preparar conjuntos *gallery/query* destinados al entrenamiento de modelos ReID. Esto convierte la curación manual del dato en una parte funcional del pipeline, no solo en una tarea auxiliar.

3.2. Oclusiones, cruces, paneos y salidas de escena

El comportamiento de un tracker en fútbol se ve fuertemente condicionado por varios fenómenos visuales recurrentes. El primero de ellos es la oclusión, tanto parcial como total. Cuando varios jugadores convergen sobre una misma zona del campo, el detector puede producir cajas degradadas, perder temporalmente alguna instancia o

generar asociaciones ambiguas. ByteTrack mostró que recuperar detecciones de baja confianza ayuda a reducir fragmentación causada por oclusiones y bajas puntuaciones del detector [7]; sin embargo, en escenas deportivas con interacción intensa la mera recuperación de detecciones no garantiza por sí sola la coherencia de identidad.

Un segundo fenómeno crítico son los cruces entre trayectorias. Cuando dos o más jugadores intercambian posiciones relativas en pocos fotogramas, la asociación basada exclusivamente en proximidad geométrica puede inducir cambios de identidad si no existe una señal de apariencia suficientemente discriminativa. Deep SORT ya argumentaba que la incorporación de una métrica profunda de apariencia resulta especialmente útil para sostener identidades a través de oclusiones y cruces prolongados [6]. No obstante, en fútbol esa señal de apariencia puede ser ambigua debido a la similitud entre compañeros, de modo que ni la geometría ni la apariencia son completamente fiables por separado.

El tercer factor es el movimiento de cámara. En vídeo de retransmisión, los paneos y cambios de zoom alteran continuamente la localización aparente y la escala de los jugadores. Esto introduce errores tanto en la predicción dinámica del tracker como en la comparación visual entre recortes de una misma identidad tomados bajo perspectivas distintas. SoccerNet-Tracking destaca precisamente que las secuencias de fútbol contienen escenarios especialmente complejos en presencia de movimiento rápido y oclusión severa [2]. En un contexto amateur, donde la estabilización y la calidad óptica suelen ser peores, este efecto puede resultar todavía más acusado.

Finalmente, las salidas y reentradas de escena generan un problema de largo alcance. Un jugador puede abandonar el campo visual por un lateral y reaparecer decenas de fotogramas después en una posición muy distinta debido al paneo de cámara. Si la memoria temporal del tracker es demasiado corta, se fragmenta la trayectoria; si es demasiado larga, aumenta el riesgo de reasignaciones geoméricamente imposibles. Por ello, uno de los retos centrales del trabajo consiste en encontrar un equilibrio entre persistencia temporal, asociación visual y plausibilidad espacial.

3.3. Coherencia de identidad y coherencia geométrica

En este trabajo se distinguen dos nociones que, aunque relacionadas, no son equivalentes: la coherencia de identidad y la coherencia geométrica.

La coherencia de identidad hace referencia a la capacidad del sistema para mantener el mismo identificador asignado a un jugador a lo largo del vídeo, evitando fragmentación excesiva, cambios de identidad y reutilización errónea de IDs. Esta dimensión suele reflejarse en métricas como IDF1, número de *ID switches*, fragmentaciones o

número total de identidades generadas por el sistema [1, 7]. En aplicaciones deportivas, esta propiedad es esencial para poder reconstruir trayectorias largas y extraer estadísticas fiables por jugador.

La coherencia geométrica, en cambio, se refiere a la plausibilidad espacial y temporal de las asociaciones realizadas por el tracker. Un sistema puede producir pocas identidades totales y, aun así, cometer errores físicamente incoherentes, por ejemplo reasignando un mismo ID a detecciones separadas por distancias incompatibles con el movimiento real del jugador entre fotogramas consecutivos o tras una breve desaparición. Este tipo de fallo no siempre queda suficientemente penalizado por las métricas MOT agregadas, especialmente cuando la reducción del número de IDs se logra a costa de fusiones demasiado agresivas.

La experiencia experimental de este TFG llevó precisamente a identificar que una parte del problema no era solo “cuántos IDs” producía el sistema, sino “cómo” se mantenían esos IDs. Por ello, la evaluación no se limita a métricas globales, sino que incorpora también inspección cualitativa de trayectorias, análisis de saltos espaciales y revisión de casos donde el tracker genera asociaciones que, aun reduciendo fragmentación, resultan visualmente inverosímiles. Esta distinción será clave para justificar más adelante la combinación de ReID online y *tracklet linking* offline.

3.4. Preguntas de investigación

A partir del contexto anterior, el trabajo se articula en torno a las siguientes preguntas de investigación:

- ¿Qué tracker ofrece el mejor punto de partida para seguimiento de jugadores en fútbol dentro de un esquema modular y reproducible?
- ¿Hasta qué punto el módulo de re-identificación aporta información útil en este dominio, y qué limitaciones presenta cuando la apariencia entre jugadores es altamente similar?
- ¿Es preferible integrar la señal ReID durante el proceso online de asociación o utilizarla, directa o indirectamente, en un postprocesado offline sobre tracklets ya formados?
- ¿Cómo afecta el dominio de entrenamiento del modelo ReID al rendimiento final del tracking, comparando un modelo genérico con modelos específicos para fútbol profesional y amateur?
- ¿Puede un postprocesado geométrico de *tracklet linking* corregir fragmentaciones e incoherencias espaciales que el tracker online no resuelve adecuadamente?

- ¿Qué combinación final de modelo ReID, configuración del tracker y linking ofrece el mejor equilibrio entre continuidad de identidad, reducción de fragmentación y plausibilidad geométrica?

Estas preguntas sintetizan la evolución real del proyecto: desde una comparación inicial de trackers hasta una investigación más precisa sobre cómo se representa, se utiliza y se corrige la identidad en el pipeline de seguimiento.

3.5. Hipótesis de trabajo

La primera hipótesis del trabajo es que ByteTrack constituye una base adecuada para el dominio del fútbol por su robustez como tracker *tracking-by-detection* y por su capacidad para aprovechar detecciones de baja confianza, algo especialmente útil en presencia de oclusiones [7]. Sin embargo, se plantea que su rendimiento en fútbol no depende solo del tracker en sí, sino de la forma en que se integra la señal de apariencia.

La segunda hipótesis es que el módulo ReID sí contiene información útil, pero su eficacia en fútbol queda condicionada por la similitud visual entre jugadores, la baja resolución de detalles locales y la variabilidad provocada por cámara y pose. En consecuencia, se espera que la utilidad del embedding dependa menos de su mera existencia y más de cómo se combine con criterios geométricos y temporales [6, 3].

La tercera hipótesis es que el postprocesado offline mediante *tracklet linking* puede corregir parte de los errores residuales del seguimiento online, especialmente aquellos relacionados con fragmentación e incoherencias espaciales. A diferencia de la asociación online, el linking opera sobre trayectorias ya observadas y puede aplicar criterios más conservadores y globales, lo que sugiere una complementariedad potencial entre ambos enfoques.

Por último, se plantea que la adaptación del modelo ReID al dominio puede mejorar la discriminación visual respecto a un baseline genérico, aunque dicha mejora no tiene por qué traducirse linealmente en mejores métricas globales si el tracker ya impone una parte importante de la dinámica de asociación. Por ello, el trabajo no asume de partida que “más especialización del ReID” implique necesariamente “mejor sistema final”, sino que somete esa relación a validación experimental.

4. Datos, materiales y entorno experimental

4.1. Datasets utilizados

4.2. Secuencias profesionales y amateur

4.3. Ground truth y pseudo-ground-truth

4.4. Entorno tecnológico

4.5. Organización reproducible de experimentos

5. Metodología general

5.1. Diseño iterativo del trabajo

El desarrollo del TFG se ha basado en una metodología iterativa, en línea con lo ya planteado en el anteproyecto. En lugar de fijar desde el inicio un único pipeline cerrado, el trabajo se estructuró como una secuencia de ciclos de diagnóstico, modificación, evaluación y revisión. Este enfoque resultaba especialmente adecuado para un problema como el seguimiento multiobjeto en fútbol, donde una parte relevante de las dificultades no se conoce con precisión hasta observar el comportamiento real de los modelos sobre secuencias concretas de vídeo.

La idea central de esta metodología fue avanzar desde niveles bajos de análisis hacia niveles más altos de integración. En una primera fase se compararon varios trackers y se identificaron sus fallos más evidentes. A continuación, se profundizó en el problema de identidad, primero mediante análisis visual y cuantitativo de trayectorias, y después mediante el estudio del módulo ReID de forma aislada. Sobre esa base, se plantearon dos líneas complementarias de mejora: la recalibración online de la asociación en ByteTrack y el postprocesado offline mediante *tracklet linking*. Finalmente, el trabajo se extendió al entrenamiento de modelos ReID específicos de dominio y a la construcción de una herramienta de apoyo para ejecutar el pipeline completo.

Este diseño iterativo también permitió incorporar de forma natural el feedback de las tutorías. A lo largo del proyecto, distintas decisiones metodológicas fueron reformuladas a partir de resultados intermedios: por ejemplo, la ampliación de métricas más allá de MOTA e IDF1, la revisión del papel del `track_buffer`, la necesidad de introducir análisis cualitativo para detectar incoherencias geométricas o el cambio de foco desde ajustes puramente online hacia el estudio del *tracklet linking* offline. En consecuencia, la metodología del trabajo no debe entenderse como una sucesión rígida de experimentos independientes, sino como un proceso acumulativo de validación y refinamiento.

5.2. Flujo general del pipeline

El pipeline general del TFG se articula en torno a una arquitectura modular, formada por cuatro grandes bloques: detección, tracking online, postprocesado offline y evaluación. Esta separación resulta útil tanto desde el punto de vista experimental como desde el punto de vista práctico, ya que permite aislar con claridad qué componente es responsable de cada mejora o degradación observada.

En primer lugar, se parte de un detector de personas basado en YOLOX, integrado dentro del ecosistema de ByteTrack. Sobre esas detecciones se ejecuta el proceso de seguimiento online, utilizando ByteTrack como tracker base y, dependiendo de la configuración, incorporando o no un módulo ReID basado en embeddings OS-Net. Esta fase produce como salida un fichero de tracking en formato MOT, que constituye la representación estándar de las trayectorias generadas por el sistema.

En segundo lugar, opcionalmente se aplica un postprocesado offline de *tracklet linking*. A diferencia del tracking online, esta etapa no modifica la asociación frame a frame mientras el vídeo se procesa, sino que opera a posteriori sobre trayectorias ya cerradas. Su función es detectar fragmentos compatibles y fusionarlos cuando exista suficiente evidencia temporal, espacial y, en algunas variantes, visual. Este enfoque permite introducir restricciones más conservadoras y reducir ciertos errores geométricos residuales que no siempre quedan bien resueltos durante la asociación online.

En tercer lugar, el pipeline incluye una capa de visualización y análisis. Esta capa sirve para generar vídeo etiquetado, inspeccionar trayectorias y revisar de forma manual casos dudosos. En el contexto amateur, esta parte del flujo adquirió especial importancia, ya que fue necesario depurar salidas MOT para construir un *pseudo-ground truth* suficientemente consistente como para calcular métricas y preparar conjuntos de entrenamiento ReID en formato *gallery/query*.

Por último, el pipeline incorpora una etapa de evaluación cuantitativa y cualitativa. Cuando existe *ground truth*, se calculan métricas estándar de MOT; cuando no existe, la evaluación debe apoyarse con más fuerza en la inspección manual, la revisión de trayectorias y el análisis de errores estructurales. De este modo, la metodología combina reproducibilidad automatizada y análisis experto, evitando depender exclusivamente de un único tipo de evidencia.

5.3. Protocolo de evaluación cuantitativa

La evaluación cuantitativa se diseñó para comparar configuraciones de tracking y ReID de forma homogénea y reproducible. Para ello se utilizaron métricas estándar del campo MOT, en particular MOTA, IDF1, HOTA, número de *ID switches*, fragmentaciones y número total de identidades generadas por el sistema. Estas métricas ofrecen perspectivas complementarias: MOTA resume errores globales de detección y asociación; IDF1 mide consistencia de identidad; HOTA intenta equilibrar calidad de detección y asociación; mientras que *ID switches*, fragmentaciones y Total IDs resultan especialmente útiles para analizar la estabilidad de las trayectorias en vídeo deportivo [1, 7, 2].

A nivel de implementación, el protocolo se apoyó en dos motores principales: `motmetrics` y `trackeval`. Durante el desarrollo fue necesario revisar el evaluador para corregir problemas de alineación temporal entre el formato del *ground truth* y la salida del tracker, especialmente en relación con el indexado de frames. Esta revisión fue importante porque pequeñas inconsistencias en la correspondencia temporal pueden alterar sensiblemente las métricas de asociación y generar comparaciones engañosas entre configuraciones.

Además de las métricas estándar, en determinadas fases del trabajo se incorporaron medidas derivadas más específicas del dominio, como *ID switches* por minuto, *ID switches* por jugador y minuto o número total de IDs producidos en un clip. La razón para hacerlo fue que, en un contexto de seguimiento de futbolistas, no basta con optimizar métricas globales si al mismo tiempo el sistema produce una fragmentación excesiva o multiplica artificialmente el número de trayectorias asignadas. En otras palabras, la evaluación cuantitativa se orientó no solo a “maximizar una métrica”, sino a capturar mejor la continuidad real de identidad en escenarios deportivos.

Por último, conviene señalar que no todos los experimentos tienen el mismo estatus dentro de la memoria. Los resultados que se consideran definitivos son aquellos obtenidos con el protocolo ya estabilizado y comparables entre sí; en cambio, ciertos análisis exploratorios se conservaron únicamente como referencia metodológica o como prueba de hipótesis intermedias. Esta distinción se explicará con más detalle en la Sección 5.5.

5.4. Protocolo de evaluación cualitativa

Aunque las métricas MOT son indispensables para comparar configuraciones, la experiencia acumulada durante el proyecto mostró que no son suficientes por sí solas para valorar la calidad real del seguimiento en fútbol. En particular, pueden existir trayectorias con pocas identidades totales o pocos cambios aparentes de ID que, sin embargo, contengan reasignaciones espacialmente imposibles o saltos visualmente inverosímiles. Por ello, se estableció desde fases tempranas un protocolo de evaluación cualitativa complementario.

Este protocolo se basó en la inspección manual de secuencias seleccionadas, la generación de vídeo etiquetado y la revisión de casos anómalos detectados cuantitativamente. Entre los fenómenos de interés destacaron: cruces entre jugadores, desaparición y reaparición de trayectorias, duplicación de identidades, teletransportación de un mismo ID entre zonas incompatibles del campo visual y asignaciones residuales sobre árbitros o jugadores distintos. Estos análisis permitieron identificar problemas que luego orientaron tanto la recalibración online de ReID como el diseño del linking

offline.

La evaluación cualitativa no se utilizó como sustituto de las métricas, sino como criterio de validación estructural. Cuando dos configuraciones presentaban resultados cuantitativos cercanos, la plausibilidad geométrica y la coherencia visual de las trayectorias servían para interpretar mejor cuál de ellas resultaba más adecuada para el dominio. Esta idea fue particularmente importante en la elección final del pipeline, donde una pequeña degradación en alguna métrica global podía resultar aceptable si se corregían errores graves de consistencia espacial.

En el caso amateur, el análisis cualitativo tuvo además una función adicional: facilitar la curación manual de salidas MOT para construir un *pseudo-ground truth*. Los scripts desarrollados para revisión interactiva permitieron corregir IDs, eliminar duplicados y ajustar asociaciones dudosas, lo que posteriormente hizo posible tanto la evaluación sobre secuencias amateur como el entrenamiento de modelos ReID específicos.

5.5. Jerarquía de resultados: definitivos frente a exploratorios

Una parte importante de la solidez metodológica del trabajo consiste en distinguir entre resultados definitivos y resultados exploratorios. A lo largo del desarrollo se generaron numerosos informes intermedios, algunos de los cuales fueron útiles para descartar hipótesis o para orientar decisiones posteriores, pero no todos deben recibir el mismo peso en la memoria final.

En esta memoria se consideran **resultados definitivos** aquellos obtenidos con el protocolo de evaluación ya estabilizado, sobre configuraciones comparables y con un objetivo claramente integrado en el pipeline final del TFG. En particular, esta categoría incluye la evaluación final de modelos ReID genéricos y específicos por dominio, así como los experimentos de aplicación de *tracklet linking* sobre dichos modelos. Estos bloques son los que sustentan la selección final del sistema.

Por el contrario, se consideran **resultados exploratorios** aquellos experimentos cuyo propósito principal fue contrastar hipótesis parciales durante el desarrollo, por ejemplo comprobar si el peso efectivo del ReID en la función de asociación era demasiado bajo o si una implementación alternativa de fusión alteraba sustancialmente el comportamiento del tracker. Aunque estos experimentos ofrecen información valiosa sobre la evolución del proyecto, no siempre son directamente comparables con la configuración final y, por tanto, se tratan en la memoria como evidencia secundaria o como apoyo metodológico.

Esta jerarquización cumple una doble función. En primer lugar, evita mezclar en

el mismo plano resultados consolidados y pruebas de depuración o sensibilidad. En segundo lugar, permite contar de forma honesta el proceso real del TFG: no como una secuencia lineal sin incertidumbre, sino como una investigación aplicada en la que algunas líneas se confirmaron, otras se reformularon y otras se descartaron tras su validación experimental.

6. Comparativa inicial de trackers

Estructura del análisis

Objetivo del experimento

Comparar varios trackers representativos sobre una misma secuencia de fútbol para identificar cuál ofrecía el mejor punto de partida para el desarrollo posterior del TFG.

Material usado

Tablas de evaluación inicial sobre SNMOT-060, vídeos generados en las primeras pruebas y conversaciones con tutores sobre paradigmas de tracking tradicionales frente a métodos end-to-end.

Configuración

Secuencia SNMOT-060 de SoccerNet, aproximadamente 750 frames y 30 segundos de duración. Se evaluaron ByteTrack sin ReID, ByteTrack con ReID OSNet entrenado en SportsMOT, DeepEIoU con el mismo modelo ReID y MOTIP con pesos oficiales entrenados sobre SportsMOT. La evaluación se realizó con métricas MOT estándar y, posteriormente, con métricas ampliadas que incluían fragmentaciones y número total de IDs.

Resultados principales

ByteTrack sin ReID mostró el mejor equilibrio global en la comparación inicial, mientras que ByteTrack con ReID redujo cambios de identidad e IDs totales a costa de una ligera degradación en métricas globales. DeepEIoU presentó una fragmentación claramente superior y MOTIP mostró peor estabilidad global en este dominio.

Interpretación

La comparación inicial sugirió que el problema no era únicamente “usar o no usar ReID”, sino elegir una base modular suficientemente sólida sobre la que analizar después la asociación de identidad.

Limitaciones

Estas pruebas corresponden a una fase inicial del trabajo y todavía no incorporan ni la recalibración del evaluador ni las mejoras posteriores del

pipeline. Por tanto, deben leerse como una comparación exploratoria para selección de base, no como resultados finales del TFG.

Conclusión parcial

ByteTrack fue seleccionado como tracker base del trabajo por ofrecer el mejor equilibrio entre rendimiento, interpretabilidad y capacidad de modificación experimental.

6.1. Selección de trackers candidatos

La primera fase experimental del trabajo se planteó como una comparación entre varios trackers representativos de paradigmas distintos. El objetivo no era todavía optimizar un sistema final, sino determinar qué enfoque ofrecía una base más sólida para el dominio del fútbol. En las conversaciones iniciales con los tutores se planteó explícitamente comparar métodos tradicionales del paradigma *tracking-by-detection*, donde el tracking y la asociación pueden modularse por separado, frente a enfoques más integrados o *end-to-end*, como MOTIP, donde la identidad se aprende de forma más directa dentro del propio sistema.

Siguiendo este criterio, se seleccionaron cuatro configuraciones iniciales. La primera fue ByteTrack sin ReID, utilizada como línea base del paradigma modular. La segunda fue ByteTrack con un modelo ReID OSNet entrenado en SportsMOT, con el fin de comprobar si la incorporación de apariencia mejoraba la continuidad de identidad. La tercera fue DeepEIoU, también combinado con el mismo modelo ReID, como alternativa basada en un esquema de tracking deportivo con distinta política de asociación. Finalmente, se incluyó MOTIP como representante de un enfoque más reciente basado en transformers y predicción de identidad.

Esta selección resultó metodológicamente útil porque permitía responder simultáneamente a dos preguntas. Por un lado, si un tracker modular fuerte como ByteTrack era suficiente como base de trabajo. Por otro, si un método más integrado como MOTIP podía ofrecer ventajas en un escenario deportivo complejo sin necesidad de incorporar un módulo ReID explícito.

6.2. ByteTrack

ByteTrack se utilizó como referencia principal de la familia *tracking-by-detection*. La razón de esta elección fue doble. En primer lugar, se trata de un tracker con muy buen rendimiento en la literatura reciente y con una filosofía especialmente

interesante para escenarios con detecciones degradadas: en vez de descartar de manera temprana las cajas de baja confianza, intenta asociarlas también, recuperando instancias verdaderas que de otro modo fragmentarían la trayectoria. En segundo lugar, su implementación permite intervenir de forma relativamente sencilla en parámetros, lógica de asociación y acoplamiento con módulos ReID, lo que lo convertía en una base muy adecuada para un TFG centrado en análisis y modificación del pipeline.

En la comparación inicial, ByteTrack sin ReID obtuvo un rendimiento cuantitativo muy competitivo: 80.7 % de MOTA, 75.6 % de IDF1 y 41 ID switches. Además, en la tabla ampliada aparecía con 119 fragmentaciones y 62 IDs totales, lo que evidenciaba que, aunque la calidad global del tracking era alta, seguía existiendo un problema apreciable de fragmentación de identidades. Esta combinación de buen rendimiento base y margen claro de mejora fue precisamente una de las razones por las que ByteTrack resultó especialmente atractivo como punto de partida.

Cuando se añadió un modelo OSNet entrenado en SportsMOT, ByteTrack pasó a 79.2 % de MOTA y 74.4 % de IDF1, pero redujo los ID switches de 41 a 36 y, sobre todo, redujo drásticamente los IDs totales de 62 a 30. Esta observación fue importante desde el principio, porque sugería que la señal ReID sí estaba aportando continuidad de identidad, aunque su integración no resultaba todavía óptima y generaba un trade-off entre compactación de identidades y calidad global del seguimiento.

6.3. DeepEIoU

DeepEIoU se incluyó como tracker alternativo dentro del conjunto de métodos probados en la fase inicial. Su interés residía en comprobar si un enfoque ya orientado a escenarios deportivos podía superar a ByteTrack al combinar asociación geométrica y apariencia. Para mantener la comparabilidad, se utilizó también un modelo OSNet entrenado en SportsMOT.

Los resultados cuantitativos mostraron que DeepEIoU alcanzaba 80.9 % de MOTA y 75.2 % de IDF1, es decir, un valor de MOTA ligeramente superior al de ByteTrack sin ReID. Sin embargo, esta aparente ventaja desaparecía al observar las métricas de identidad: 60 ID switches, 154 fragmentaciones y 67 IDs totales. En otras palabras, el tracker mantenía una calidad global aceptable en términos de detección y cobertura, pero lo hacía a costa de una estabilidad de identidad claramente peor.

Este comportamiento fue muy relevante para la selección del sistema base. La comparación mostraba que una métrica global ligeramente mejor no implicaba necesariamente un mejor tracker para el problema concreto del TFG. En un dominio donde

la continuidad de identidad es un objetivo central, el número de cambios de ID y la fragmentación pesan más que una mejora marginal en MOTA. Por ello, aunque DeepEIoU se conservó como referencia comparativa, no se consideró la mejor base para el desarrollo posterior.

6.4. MOTIP

MOTIP se incorporó a la comparativa como representante de un paradigma distinto al de los trackers modulares clásicos. A diferencia de ByteTrack o DeepEIoU, no sigue la filosofía de *tracking-by-detection* con un módulo ReID acoplado, sino que plantea el seguimiento como un problema de predicción de identidad más integrado. Precisamente por ello resultaba interesante incluirlo en la fase inicial: permitía contrastar un método más reciente y cercano al paradigma *end-to-end* frente a los trackers tradicionales.

Sin embargo, los resultados cuantitativos iniciales fueron claramente peores que los de ByteTrack. MOTIP obtuvo 73.1 % de MOTA, 71.0 % de IDF1 y 51 ID switches. En la tabla ampliada, además, aparecía con 350 fragmentaciones y 61 IDs totales, cifras que reflejaban una inestabilidad notable de las trayectorias. Esta degradación no solo se observó en las métricas, sino también en el análisis visual posterior, donde se documentaron fenómenos de reciclaje de identidades, teletransportación por paneo de cámara y creación de IDs fantasma durante oclusiones y caídas de jugadores.

Desde el punto de vista metodológico, la inclusión de MOTIP fue, aun así, muy valiosa. Permitió comprobar que el paradigma alternativo era interesante desde un punto de vista conceptual, pero que en el dominio concreto del fútbol y bajo el protocolo experimental del TFG no constituía la mejor base para construir mejoras progresivas. Además, su menor modularidad lo hacía menos conveniente para un trabajo cuyo objetivo no era solo comparar resultados, sino intervenir explícitamente en la lógica de asociación e identidad.

6.5. Resultados iniciales y selección del tracker base

La comparación inicial permite extraer una conclusión clara. Si se observa únicamente MOTA, ByteTrack sin ReID y DeepEIoU ofrecen valores similares, e incluso DeepEIoU aparece ligeramente por encima. Sin embargo, al incorporar métricas de identidad y fragmentación, la diferencia entre métodos se vuelve mucho más clara. ByteTrack sin ReID logra el mejor equilibrio entre rendimiento global y estabilidad de identidad dentro de la comparación inicial, mientras que ByteTrack con ReID muestra ya una reducción notable de ID switches e IDs totales, aunque todavía con

un trade-off no resuelto en MOTA e IDF1.

En cambio, DeepEIoU y MOTIP quedan por detrás cuando el criterio se desplaza desde la mera cobertura global hacia la continuidad real de identidad. DeepEIoU incrementa fuertemente los cambios de ID y la fragmentación, y MOTIP presenta un comportamiento todavía más inestable, tanto cuantitativa como visualmente. Por ello, ambos métodos se conservaron como referencia comparativa, pero no como base principal del desarrollo posterior.

La decisión final de esta fase fue seleccionar ByteTrack como tracker base del TFG. Esta elección se apoyó en tres razones. En primer lugar, ofrecía el mejor equilibrio inicial entre métricas globales y continuidad de identidad. En segundo lugar, permitía experimentar de forma controlada con la integración de ReID, el ajuste de memoria temporal y la modificación de la función de asociación. Finalmente, su carácter modular lo hacía compatible con el tipo de contribución que se buscaba en este trabajo: no solo evaluar trackers existentes, sino analizar por qué fallan y proponer mecanismos concretos para mejorar su comportamiento en fútbol.

7. Diagnóstico del problema de identidad

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

7.1. Análisis visual de fallos en ByteTrack

7.2. Casos críticos: oclusiones, jugador caído y teletransportación

7.3. Influencia del `track_buffer`

7.4. Heurísticas tempranas y sus limitaciones

7.5. Conclusión del diagnóstico

8. Análisis del módulo ReID

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

8.1. Modelo OSNet y embeddings

8.2. Verificación inicial del extractor ReID

8.3. Análisis experimental de embeddings

8.4. Separabilidad por identidad y por equipo

8.5. Discusión: problema del embedding frente a problema de integración

9. Integración online de ReID en ByteTrack

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

9.1. Configuración base v1

9.2. Recalibración de la fusión IoU–ReID

9.3. Experimentos v0, v1, v2 y v3

9.4. Evaluación cualitativa de v1

9.5. Trade-offs del enfoque online

10. Postprocesado offline mediante tracklet linking

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

10.1. Motivación del tracklet linking

10.2. Construcción y análisis de tracklets

10.3. Linking geométrico y criterios de fusión

10.4. Experimentos principales sobre v0

10.5. Aplicación sobre v1

10.6. Generalización a múltiples secuencias

10.7. Discusión: online frente a offline

11. Adaptación del ReID al dominio

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

11.1. Modelo baseline SportsMOT

11.2. Entrenamiento específico en fútbol profesional

11.3. Entrenamiento específico en fútbol amateur

11.4. Curvas de aprendizaje y selección de checkpoints

11.5. Comparación entre modelos genéricos y específicos

11.6. Aplicación de tracklet linking sobre los mejores modelos

12. Curación manual de resultados y herramienta de apoyo

12.1. Necesidad de corrección manual en salidas MOT

12.2. Script `annotate_review.py`

12.3. Script `annotate_review_precise.py`

12.4. Aplicación web Gradio del pipeline completo

12.5. Utilidad práctica dentro del flujo experimental

12.6. Limitaciones actuales de la herramienta

13. Resultados globales y selección del sistema final

Estructura del análisis

Objetivo del experimento

Escribir aquí qué pregunta responde este bloque.

Material usado

Informes, tablas, vídeos, scripts, datasets.

Configuración

Modelo, tracker, parámetros, secuencias, motor de evaluación.

Resultados principales

Métricas y observaciones clave.

Interpretación

Qué significan esos resultados.

Limitaciones

Qué no demuestra todavía este bloque.

Conclusión parcial

Qué decisión o conclusión deja cerrada antes del siguiente capítulo.

13.1. Megatabla de configuraciones

13.2. Comparación global de enfoques

13.3. Criterios de selección del sistema final

13.4. Pipeline final elegido y justificación

13.5. Discusión sobre trade-offs

14. Conclusiones

14.1. Respuesta a los objetivos del anteproyecto

14.2. Principales hallazgos

14.3. Aportaciones del trabajo

14.4. Limitaciones

14.5. Trabajo futuro

Referencias

- [1] Gioele Ciaparrone et al. «Deep Learning in Video Multi-Object Tracking: A Survey». En: *Neurocomputing* (2020).
- [2] Anthony Cioppa et al. «SoccerNet-Tracking: Multiple Object Tracking Dataset and Benchmark in Soccer Videos». En: *arXiv preprint arXiv:2204.06918* (2022).
- [3] Yutao Cui et al. «SportsMOT: A Large Multi-Object Tracking Dataset in Multiple Sports Scenes». En: *arXiv preprint arXiv:2304.05170* (2023).
- [4] Ruopeng Gao, Yijun Zhang y Limin Wang. «Multiple Object Tracking as ID Prediction». En: *arXiv preprint arXiv:2403.16848* (2024).
- [5] Jonathon Luiten et al. «HOTA: A Higher Order Metric for Evaluating Multi-Object Tracking». En: *arXiv preprint arXiv:2009.07736* (2020).
- [6] Nicolai Wojke, Alex Bewley y Dietrich Paulus. «Simple Online and Realtime Tracking with a Deep Association Metric». En: *arXiv preprint arXiv:1703.07402* (2017).
- [7] Yifu Zhang et al. «ByteTrack: Multi-Object Tracking by Associating Every Detection Box». En: *arXiv preprint arXiv:2110.06864* (2021).



UNIVERSIDAD
DE MÁLAGA

| **uma.es**

E.T.S. DE INGENIERÍA INFORMÁTICA

E.T.S de Ingeniería Informática
Bulevar Louis Pasteur, 35
Campus de Teatinos
29071 Málaga