

1. Estado del arte

1.1. Multi-Object Tracking

El problema de *Multi-Object Tracking* (MOT) consiste en estimar la trayectoria de múltiples objetos a lo largo del tiempo manteniendo una identidad consistente para cada uno de ellos. En visión por computador, esta tarea suele abordarse sobre secuencias de vídeo monocámara y combina dos subproblemas fundamentales: la localización de los objetos en cada fotograma y su asociación temporal entre fotogramas consecutivos o distantes (**ciaparrone2020survey**; **zhang2022bytetrack**).

Aunque buena parte de la literatura se ha desarrollado sobre escenarios peatonales y urbanos, el MOT sigue siendo un problema abierto cuando aparecen oclusiones prolongadas, interacciones densas, cambios bruscos de movimiento o degradación de la apariencia. En estos casos, el rendimiento del tracker depende no solo de la calidad del detector, sino también de la forma en que combina información geométrica, temporal y visual para preservar identidades consistentes (**ciaparrone2020survey**; **hota2020**).

Desde un punto de vista metodológico, la evolución reciente del MOT puede entenderse a partir de dos grandes familias de enfoques: por un lado, los métodos modulares basados en detección, conocidos como *tracking-by-detection*; por otro, los métodos más integrados o *end-to-end*, entre los que destacan varias propuestas basadas en transformers y en predicción directa de identidad. Esta distinción es especialmente relevante para el presente TFG, ya que parte del trabajo consistió precisamente en comparar ambos paradigmas antes de centrar el desarrollo en un pipeline modular.

1.2. Re-Identification

La *Re-Identification* (ReID) es una técnica orientada a representar una identidad mediante un embedding de apariencia que permita comparar recortes de una misma persona u objeto a lo largo del tiempo. En un pipeline de tracking, su función es complementar la asociación geométrica con una señal visual capaz de sostener identidades incluso cuando la predicción dinámica resulta ambigua. En la práctica, un modelo ReID transforma cada recorte en un vector de características y la similitud entre esos vectores se utiliza como criterio adicional de asociación (**wojke2017deepsort**; **ciaparrone2020survey**).

La incorporación de embeddings profundos a la asociación temporal se popularizó

con Deep SORT, que mostró que una métrica de apariencia aprendida podía reducir los cambios de identidad frente a métodos puramente geométricos (**wojke2017deepsort**). Desde entonces, muchos trackers han incorporado módulos ReID como parte central o auxiliar de su estrategia de asociación, especialmente en escenarios donde las oclusiones, los cruces y las desapariciones temporales son frecuentes.

Sin embargo, la utilidad de la ReID depende fuertemente del dominio. En escenas deportivas, y en particular en deportes de equipo, la apariencia entre instancias es simultáneamente parecida y potencialmente discriminativa: varios jugadores comparten colores y estructura visual global, pero pueden diferenciarse por dorsal, textura, pose o detalles locales. SportsMOT subraya que precisamente esta mezcla de movimiento rápido y apariencia redundante convierte la asociación de identidades en el reto dominante del tracking deportivo (**cui2023sportsmot**). Por ello, la efectividad del ReID no depende únicamente de su arquitectura, sino también del dominio en que se entrena y de cómo se integra dentro del tracker.

1.3. Paradigmas de seguimiento: *tracking-by-detection* frente a métodos *end-to-end*

El paradigma más extendido en MOT durante los últimos años ha sido el *tracking-by-detection*. En este esquema, la detección y la asociación se resuelven en etapas separadas: primero se detectan los objetos en cada fotograma y después se enlazan temporalmente mediante información de movimiento, solapamiento espacial, heurísticas de asignación y, en muchos casos, embeddings de apariencia (**ciaparrone2020survey**; **wojke2017deepsort**; **zhang2022bytetrack**). Este enfoque tiene como principal ventaja su modularidad: cada componente puede mejorarse o sustituirse sin necesidad de rediseñar por completo el sistema.

Deep SORT constituye un ejemplo representativo de esta familia. El método combina un filtro de Kalman para modelar el movimiento, una estrategia clásica de asignación y una métrica profunda de apariencia para reforzar la asociación (**wojke2017deepsort**). Posteriormente, otros métodos mantuvieron esta filosofía modular, aunque introduciendo mejoras específicas en la política de asociación. ByteTrack, por ejemplo, demostró que una parte importante de la fragmentación proviene de descartar demasiado pronto detecciones de baja confianza. Su propuesta consiste en asociar prácticamente todas las cajas de detección, incluidas aquellas con score menor, recuperando así instancias verdaderas que otros trackers perderían (**zhang2022bytetrack**). Esta idea resulta especialmente interesante en escenas con oclusión, donde las detecciones válidas tienden a degradarse temporalmente.

Frente a este paradigma modular, en los últimos años han aparecido métodos más integrados o *end-to-end*, en los que la identidad deja de resolverse únicamente como una asignación posterior basada en heurísticas y se incorpora de forma más directa al propio proceso de predicción. Dentro de esta familia se encuentran varias propuestas basadas en transformers, que aprovechan su capacidad para modelar relaciones globales y dependencias temporales entre múltiples objetos. Estos enfoques aspiran a aprender de forma conjunta qué trayectorias deben mantenerse y cómo propagar la identidad a lo largo del tiempo, reduciendo la dependencia de reglas diseñadas manualmente.

MOTIP ejemplifica bien esta línea de trabajo. En lugar de formular el problema exclusivamente como una asociación entre detecciones frame a frame, plantea el tracking como un problema de predicción de identidad a partir del contexto histórico de las trayectorias (**motip2024**). Conceptualmente, esto desplaza parte de la carga del sistema desde el diseño explícito de funciones de coste y reglas de matching hacia un mecanismo aprendido que intenta decidir directamente qué identidad corresponde a cada observación.

Ambos paradigmas presentan fortalezas y debilidades. Los métodos *tracking-by-detection* suelen ser más interpretables, modulares y fáciles de adaptar cuando se desea reemplazar detector, módulo ReID o postprocesado de manera independiente. Los métodos *end-to-end*, por el contrario, pueden capturar dependencias más complejas y reducir la necesidad de heurísticas manuales, pero a cambio suelen ser menos transparentes y más dependientes del dominio de entrenamiento y de la calidad del protocolo experimental (**zhang2022bytetrack**; **motip2024**). En el contexto del presente trabajo, esta diferencia resultó especialmente relevante: mientras los métodos modulares ofrecían una base clara sobre la que analizar y modificar componentes, los métodos más integrados servían como referencia valiosa de un paradigma alternativo, aunque menos sencillo de intervenir.

1.4. Seguimiento de jugadores en deporte y fútbol

El tracking en deporte comparte la estructura general del MOT, pero introduce dificultades específicas que lo convierten en un dominio especialmente exigente. SportsMOT muestra que los deportes combinan dos propiedades difíciles de resolver simultáneamente: movimiento rápido y variable, y apariencias muy parecidas entre instancias que, aun así, deben distinguirse correctamente (**cui2023sportsmot**). En consecuencia, la asociación es particularmente frágil cuando depende solo de proximidad geométrica o de una apariencia poco discriminativa.

En fútbol, además, el problema tiene una dimensión contextual muy marcada.

SoccerNet-Tracking fue propuesto para cubrir la falta de benchmarks específicos de tracking en vídeo futbolístico y puso de manifiesto que el seguimiento conjunto de jugadores, árbitros y balón está lejos de estar resuelto (**cioppa2022soccernettracking**). El benchmark destaca fenómenos como oclusión severa, movimiento rápido, densidad de jugadores y dificultad para mantener identidades en secuencias largas de retransmisión.

La importancia de este problema no es únicamente académica. El tracking robusto en fútbol permite automatizar la extracción de trayectorias, estimar carga física, reconstruir ocupación espacial y facilitar análisis táctico sin necesidad de sensores invasivos, algo especialmente valioso en contextos amateur o semiprofesionales (**cioppa2022soccernettracking**; **cui2023sportsmot**). Sin embargo, precisamente en esos contextos la calidad del vídeo suele ser menor y la disponibilidad de anotaciones es más limitada, lo que amplía la distancia entre los resultados de benchmark y la aplicabilidad práctica de los sistemas.

Por ello, una parte relevante del estado del arte reciente en deporte no se limita a proponer trackers más precisos, sino que insiste en la necesidad de datasets y protocolos de evaluación ajustados al dominio. Tanto SoccerNet-Tracking como SportsMOT desempeñan en este TFG un papel central como referencias para contextualizar el problema y justificar las decisiones experimentales adoptadas.

1.5. Métricas de evaluación

La evaluación en MOT requiere medir simultáneamente calidad de detección y calidad de asociación. Tradicionalmente, una de las métricas más utilizadas ha sido MOTA, que resume errores de falsas detecciones, pérdidas y cambios de identidad en una sola magnitud agregada. Junto a ella, métricas como IDF1 ponen el foco en la consistencia de identidad, valorando hasta qué punto las trayectorias predichas corresponden correctamente con las trayectorias reales (**hota2020**).

No obstante, la literatura reciente ha señalado que estas métricas clásicas no siempre reflejan de forma equilibrada todos los tipos de error relevantes en tracking. HOTA fue propuesta precisamente para afrontar esta limitación, buscando un balance explícito entre detección y asociación y ofreciendo además descomposiciones que permiten interpretar con mayor claridad si una mejora procede de mejores detecciones o de una asociación más consistente (**hota2020**). En la práctica, HOTA se ha consolidado como una métrica especialmente útil cuando interesa valorar el comportamiento global de un tracker más allá de una única magnitud agregada.

Junto a estas métricas generales, en aplicaciones concretas resulta habitual analizar

también medidas más directamente interpretables, como el número de *ID switches*, las fragmentaciones o el número total de identidades generadas por el sistema. En escenarios deportivos, donde la continuidad por jugador resulta esencial para reconstruir trayectorias largas y extraer estadísticas fiables, estas cantidades pueden llegar a ser tan importantes como las métricas agregadas (**cioppa2022soccernettracking; hota2020**).

En consecuencia, un protocolo de evaluación sólido en MOT no debería descansar sobre una única métrica. La práctica más razonable consiste en combinar métricas globales, métricas centradas en identidad y análisis cualitativo cuando el dominio lo exige. Esta idea será central en el presente trabajo, donde la comparación entre configuraciones no se decide únicamente por la mejora de una métrica aislada, sino por el equilibrio entre continuidad de identidad, reducción de fragmentación y plausibilidad geométrica.